

# iPhone LiDARによる野生動物痕跡認識の試み： 参加型センシング基盤の構築と初期評価

古城 司<sup>1</sup> 小坂 修平<sup>1</sup> 菊池 尊勝<sup>1</sup> 佐々木 航<sup>1</sup> 松田 裕貴<sup>3</sup> 諏訪 博彦<sup>1</sup> 坪内 孝太<sup>2</sup> 安本 慶一<sup>1</sup>

**概要：**本研究は、従来の RGB 画像では捉えにくい野生動物足跡の微細な立体構造を記録・解析するため、LiDAR による三次元点群を用いた検出・分類手法を構築する。参加型センシングによる広域データ収集を前提とし、広く普及している iPhone 搭載 LiDAR センサを対象に、点群・静止画像・環境メタデータを同時取得可能な収集アプリを開発し、現場での一貫した運用フローを設計した。さらに、高密度赤外構造光方式の CR-Scan Ferret Pro 3D スキャナと同一足跡を計測し、形状再現性や点密度の差異を比較した。これにより、低密度な iPhone LiDAR 点群に基づいても実用的な検出・分類が可能であることを検証する基盤を確立した。本成果は、足跡分類の高度化に加え、住民参加型センシングを通じた広域かつ高頻度の生息域推定や生態モニタリングへの応用可能性を示す。

## 1. はじめに

野生動物による農作物被害は国内で深刻化しており、令和 5 年度（2023 年度）の年間被害額は約 164 億円に達すると報告されている [1]。この被害は経済的損失にとどまらず、農家の精神的負担や人身被害にも及び、対策の緊急性は高まっている。現状では侵入防止柵や捕獲罠の設置が広く行われているが、被害の抜本的低減には、出没傾向を高精度に把握し、罠配置や監視重点地域を戦略的に決定する必要がある。

その鍵となるのが生息域推定である。生息域を正確に推定できれば、限られた人的・物的資源を効率的に配分できる。しかし、従来の生息域推定は専門家による現地調査や高価なカメラトラップに依存しており、広域かつ高頻度なデータ取得には多大なコストと労力を要するという制約があった。

この課題に対し、我々は広域でのデータ収集を可能にする「参加型センシング」[2]の枠組みを導入してきた。これまでの収集結果から、痕跡の中でも足跡は記録数が多く、種や個体サイズ、行動時間帯など生息域推定に有用な情報を含んでいることが分かった。足跡は単なる出没位置の記録にとどまらず、行動パターンの推定や季節変動の把握に

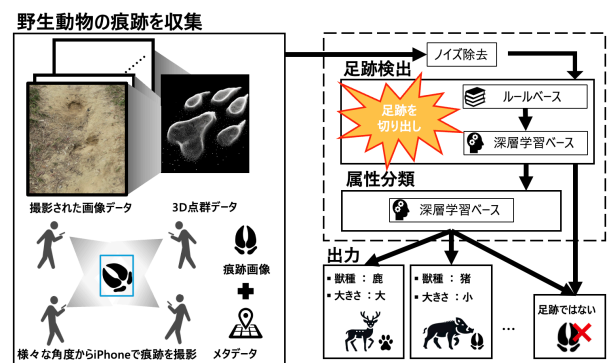


図 1: 最終的に目指す足跡検出・分類システムの全体像

も活用できる重要な痕跡である。

しかし、既存の参加型センシングシステムでは、協力者が現地で観察した痕跡の種別や位置、特徴を手動で入力する必要がある。この作業は専門知識と経験を要するため、参加できる人員は限られ、結果としてデータ収集規模の拡大に制約が生じている。さらに、専門家からは「現地では判別できても、撮影画像のみでは識別が困難である」との指摘があり、RGB 画像では足跡の凹凸形状が十分に記録されず、後処理での識別精度が著しく低下することが報告されている。

そこで本研究では、スマートフォン（iPhone）に搭載された LiDAR センサを用い、野生動物の足跡点群を取得・活用する手法を提案する。RGB 画像では取得できない三次元形状を記録することで、専門家に依存しない自動検出・分類を実現し、広域かつ高頻度な住民参加型センシングの基盤構築を目指す。

<sup>1</sup> 奈良先端科学技術大学院大学  
Nara Institute of Science and Technology  
<sup>2</sup> LINE ヤフー株式会社  
LY Corporation  
<sup>3</sup> 岡山大学  
Okayama University

本研究の最終的な目標は、図 1 に示すような「痕跡の自動検出・分類システム」を構築し、住民参加型センシングの枠組みで広域な生息域推定を可能にすることである。

本稿ではその第一歩として、次の問いに取り組む。

- 広く普及した iPhone の LiDAR センサは、野生動物の足跡認識において実用に耐えうるか？

この問いに答えるため、足跡の有無を判定する二値分類という基本タスクを設定し、専用的高密度スキャナとの性能差も含めて実証的に検証する。

本研究は、iPhone 搭載 LiDAR を軸に、点群・静止画・環境メタデータを同時取得できる現場運用可能な収集アプリと標準ワークフローを実装した。また、同一足跡を高密度赤外構造光スキャナである CR-Scan Ferret Pro（以後、Ferret Pro）でも計測してペアデータを整備し、足跡の有無を判定する二値分類に対してルールベース検出とランダムフォレストから成る初期ベースラインを提示する。

本稿で解析するのは福井県山間部での収集の中間時点データであり、収集は 2025 年 7 月 17 日から継続中（～8 月 29 日予定）である。このうち 8 月 6 日までに得られた 622 件を対象とし、評価にはその一部を用いた。概括的には、見逃しは抑えられる一方で誤検出が多い傾向が確認された。

## 2. 関連研究

### 2.1 野生動物痕跡認識に関する既存研究

野生動物観測のデータ基盤は、画像上の痕跡と映像の行動理解という二つの系統で整備が進んでいる。足跡画像については、OpenAnimalTracks[3] が 18 種の足跡を体系化し、分類・検出のベースラインを提示した。さらに AnimalClue[4] は、足跡・糞・卵・骨・羽毛という五つの間接痕跡を横断する大規模データセットを公開し、多様な課題設定に対応する注釈設計を示した。行動理解では Animal Kingdom[5] が、野外映像に対して行動認識・ポーズ推定・ビデオグラウンディングを統合し、環境変動を踏まえた学習・評価の基盤を提供している。これらの基盤は、種識別の「文脈」を二次情報や時系列へ拡張するうえで有用である。しかし、いずれも二次元データに依存しており、浅い凹凸で構成される足跡の微細な三次元形状は一次情報として扱われていない。照明や視点の変化は陰影と材質ハイライトの混同を招きやすく、趾痕の深さや縁の連続性といった手掛かりは不安定になる。

### 2.2 三次元点群処理と野外環境での課題

三次元点群認識は、座標を直接扱う PointNet 系 [6] から、局所グラフを明示化する DGCNN 系 [7]、さらに自己注意により大域文脈を取り込む Transformer 系 [8]、[9] へと発展してきた。

野外環境への応用では森林分野などで地上型 LiDAR と

深層学習の統合が進み、疎密の不均一や外乱ノイズを含む条件でも学習が成立することが報告されている [10]。しかし足跡は数センチ規模の浅い凹形状であり、周縁の鋭いエッジと中心部の緩勾配が同一スケール内に混在するため、点密度不足や奥行き量子化の粗さが直ちに識別性能へ影響する。

### 2.3 モバイル LiDAR の可能性と課題

スマートフォンに搭載された LiDAR は、屋内環境において一定の幾何精度が示されている [11]。

一方で、野外環境では直射光、地表反射、微小凹部の自己陰影などにより安定性が低下することが予想される。また、従来の LiDAR 応用研究の多くは自動運転 [12]、[13] や屋内計測 [14]、[15] といった、足跡とはスケールや性質が大きく異なる対象を扱っており、数センチ規模の野外微小形状に対する知見は限定的である。

### 2.4 本研究の位置づけ

以上の関連研究を踏まえると、「安価で普及したセンサ」を用いて「野外の微小凹形状」を認識する研究は未開拓である。本研究は、iPhone LiDAR による野生動物足跡の点群認識という新領域に挑戦し、高密度スキャナとの比較を通じてその実用可能性を実証的に検証する。

## 3. データ収集システムの設計と実装

### 3.1 設計要件

既存の iPhone 向け LiDAR 計測アプリは基本的な計測機能を備えているものの、本研究で必要とする教師データ収集の要件を満たしていなかった。特に以下の 3 点が課題として確認された：

- (1) 痕跡情報の統合管理：撮影と同時に獣種、環境条件、位置情報などのメタデータを一元的に記録する機能がない。
- (2) 連続撮影性：撮影直後に高負荷な 3D 再構成処理が自動的に開始されるため、次の対象を素早く撮影できない。
- (3) データ品質：足跡の輪郭再現に必要な撮影パラメータが不明確であり、点群にノイズが多い。

これらの課題に対応するため、本研究では現場での取得作業と計算負荷の高い後処理を分離する設計方針を採用し、Apple Object Capture のエリアモードを基盤とした専用アプリケーションを開発した。

### 3.2 システム設計

本アプリケーションは、山間部など通信環境が不安定な現場での利用を前提に、撮影作業と高負荷な後処理を明確に分離する方針で設計した。ユーザは撮影に専念できるシンプルなインタフェースを用いて対象物を記録し、撮影直



図 2: 自作アプリの撮影画面 (a) 撮影開始, (b) 撮影中, (c) 撮影完了

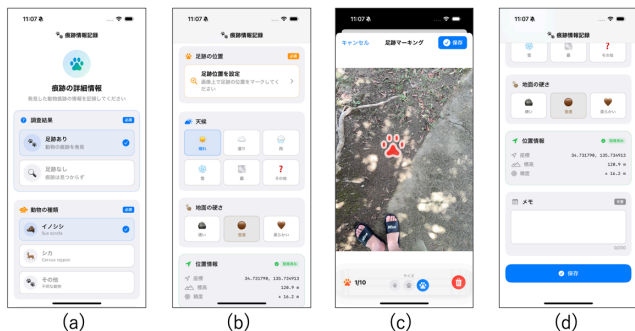


図 3: 痕跡詳細情報入力画面 (a) 足跡情報, (b) 環境条件, (c) 足跡位置アノテーション, (d) 補足メモ

後に必要なメタデータを統合的に入力できる。取得データはすべて iPhone 内に保存し、3D モデルや点群の生成はフィールド作業後にオフライン環境で実行する。これにより、現場での連続撮影性を確保するとともに、計算負荷の高い処理を安定した環境で高品質に行うことが可能となる。また、本アプリには撮影直後の個別生成、複数セッションの一括生成、およびバックグラウンド生成の各モードが備わっており、必要に応じて現場で即時可視化を行うこともできる。本研究では教師データ収集を目的としており、iPhone で撮影した画像は後処理によって 3D モデルおよび点群を生成し、Ferret Pro で取得したモデル/点群と同一形式で管理する。撮影間隔は最短 0.3 秒、撮影枚数は 1 痕跡あたり 50 枚とした。撮影間隔と撮影枚数は予備実験の結果にもとづき設定しており、対象を自然な速度で一周しながら撮影することで、隣接画像間のオーバーラップ率は Structure from Motion (SfM) の推奨範囲である 60–80% を確保している。

### 3.3 実装機能

本アプリケーションには、現場で効率的に足跡データを収集し、後処理に耐える高品質なデータを保存するための複数の機能を実装した。主な機能は「撮影フロー」「メタデータ入力」「アノテーション」「3D モデル生成」である。

まず撮影フローでは、対象物の周囲を回りながら端末を移動すると、画角変化をトリガとして静止画が自動的に取得される (図 2)。ユーザは最初に対象を画面中央に収めて「撮影開始」を押すことで計測を開始する (図 2(a))。その後、端末を持って対象の周囲を回ると自動的に静止画が記録され、進捗バーに現在の撮影枚数が表示される (図 2(b))。規定枚数 (本研究では 50 枚) に到達すると撮影は完了し、確認画面が表示される (図 2(c))。撮影終了時点では点群生成処理は行わず、ユーザは直ちに次の対象へ移行できるため、現場での連続取得性が確保される。

次に、撮影完了後には痕跡に関する詳細情報を入力する画面が表示される (図 3)。入力項目は「足跡の有無」「獣種」「足跡の位置」「天候」「地面の硬さ」であり、さらに取得地点の座標・標高・測位精度が自動で記録され、任意のメモも追加可能である。必須項目と任意項目は明確に区別されており、保存ボタンを押すことでデータは欠落なく保存される。具体的には、まず足跡の有無や獣種を選択し (図 3(a))、続いて天候や地面状態を入力する (図 3(b))。撮影画像上に足跡の位置をマーキングする機能もあり (図 3(c))、最後に位置情報や任意メモを入力・確認して終了する (図 3(d))。このように、現場で必要な環境情報を一元的に管理できる UI 設計となっている。

さらに、撮影画像上で足跡の位置をマーキングし、個数を記録するアノテーション機能を実装した (図 3(c))。ユーザは画像上で足跡をタップするだけで位置を指定でき、マーキング箇所は赤色アイコンで重畳表示されるため入力内容を即時に確認できる。複数の足跡が存在する場合も順にマーキングでき、この情報は後に検出アルゴリズムの評価に利用する参照データとして活用される。

最後に、取得したデータから 3D モデルおよび点群を生成する機能を備えている。生成方式は「個別生成」「一括生成」「バックグラウンド生成」の 3 種類に対応する。ただし本研究では教師データ収集を目的としており、現場では生成を行わず、回収後に安定した環境で一括処理を行った。

## 4. 足跡点群データ収集

### 4.1 データ収集の目的

本研究では「iPhone の LiDAR センサは野生動物の足跡認識において実用に耐えるか」という問いに答えるため、自動分類に向けた教師データの収集を行った。具体的には、LiDAR センサを搭載した iPhone 15 Pro (以後、iPhone) と、高密度計測が可能な Ferret Pro スキャナを用い、猟師の協力のもと野外環境において同一痕跡を計測したデータセットを構築した。

このデータセットは、低密度点群と高密度点群を同一条件下で対応づけて取得しており、今後の識別手法の検証に活用できる基盤を提供する。





図 4: iPhone と Ferret Pro によるデータ収集の概要

表 1: 使用機材の比較

項目	iPhone LiDAR	Ferret Pro
方式	走査型 LiDAR	赤外構造光
点群密度	約 20–30mm 間隔	約 0.2–0.5mm 間隔
計測距離	0.25–5m	0.15–2m
視野角	約 70°	約 60°
重量	約 206g	約 105g (本体)
屋外使用	可能	日陰・曇天で推奨

4.2 使用機材の比較

表 1 に両機材の主要仕様を示す。Ferret Pro は赤外構造光方式を採用し、0.2-0.5 mm 間隔の高密度点群を取得でき、微細形状の再現に優れる。一方、iPhone 15 Pro は走査型 LiDAR を用い、0.25-5 m の範囲で約 20-30 mm 間隔の点群を取得可能であり、携行性と即時性に優れる。両機材の外観および収集ブロック構成は、データ収集とペアリングの全体像を示す図 4 にも併せて掲載している。

4.3 対象と環境条件

対象は野生動物による農作物被害の主要因であるニホンジカおよびイノシシの足跡とした。その他の動物足跡については「その他」として記録し、現場で判別可能な場合には協力者が動物名をテキスト入力した。収集は 2025 年 7 月 17 日から 8 月 29 日までの約 6 週間、福井県の山間部で実施した。足跡は形状が明瞭なものに加え、部分的に崩れた足跡や判別困難な足跡も含め、多様な形態を網羅するように収集を依頼した。光条件は晴天・曇天・日陰を含む全条件を対象とし、強い直射光下でも収集を行った。環境条件および対象足跡の詳細情報は、第 3 章で述べた自作アプリの入力機能により記録した。必須項目は足跡の有無、獣種（イノシシ／シカ／その他）、足跡位置（画像上マーキング）、天候、地面状態（硬い／普通／柔らかい）、測位情報（GNSS 座標・標高・測位精度）であり、さらに任意の備考欄を設けて取得データとメタデータを一体で保存した。

4.4 データ収集フロー

本研究では、1 足跡を iPhone 15 Pro による点群とメタデータ、および Ferret Pro による高密度点群のペアとして管理する。図 4 は、このペアリングを前提とした収集から統合までの流れを示す。上段の青枠は iPhone ブロック、下段の緑枠は Ferret Pro ブロックを表す。両ブロックで得られたデータ群は収集時のタイムスタンプを基準に対応付けられ、最終的に 1 つの足跡データとして統合される。

収集は次の順序で行った。まず、iPhone 15 Pro の自作収集アプリ（第 3 章）を用い、Apple Object Capture のエリアモードで対象足跡の周囲を回り込みながら静止画と深度情報（HEIF + LiDAR データ）を自動取得した。続いて、同一の足跡について Ferret Pro の純正アプリを用い、iPhone と接続した上で対象の周囲を 0.3-0.5 m 程度の距離からゆっくり移動させて高密度点群を取得した。撮影距離は各機材の推奨範囲（表 1）に従って調整し、iPhone では 0.3-0.5 m を維持して足跡全体が画角に収まるようにし、Ferret Pro では計測距離が短いことから、しゃがんで対象に近接する姿勢をとって安定した計測を行った。撮影角度は対象の周囲を約 30-40° ずつ変化させて立体的な視差を確保し、移動速度は自然な歩行速度である約 0.2-0.3 m/s に抑えた。この条件下で iPhone は約 0.3 秒間隔で 50 枚前後の静止画を取得し、隣接画像間で 60-80 % のオーバーラップを確保して、SfM（Structure from Motion）の推奨条件を満たした。

図 4 に示す iPhone 側の取得内容は、LiDAR 付き静止画列（約 50 枚）、環境メタデータ（GNSS 座標・標高・測位精度・天候・地面状態など）、および足跡位置アノテーションである。アノテーションは撮影画像上に足跡中心をマーキングする 2 次元注釈であり、検出評価やデータ品質管理の参照情報として使用し、分類の教師ラベルとしては用いない。収集された深度情報付きの画像データから後処理により 3D モデル（PLY）および点群（PLY）を生成する。一方、Ferret Pro 側では、高密度点群（PLY）に加え、画像テクスチャに基

表 2: 収集データの内訳 (2025 年 8 月 6 日時点)

種別	件数	割合 [%]
シカ	411	66.2
イノシシ	82	13.2
その他 (不明・小動物・タヌキ等)	9	1.4
足跡なし (負例)	120	19.2
合計	622	100.0

づくカラー付き点群 (ColorMapping.ply), ノイズ除去や整合性向上を施した最適化済み点群 (Optimization.ply), 三角形メッシュ (Mesh.ply), 可搬性を重視した軽量モデル (model.ply) が出力される。両デバイスはいずれも収集セッションのフォルダ名を撮影開始時刻のタイムスタンプで統一されている。

#### 4.5 データ構成と管理

各痕跡データは, iPhone 側と Ferret Pro 側でそれぞれ撮影開始時刻をフォルダ名として保存し, 研究室サーバに転送した。両機材のデータは, 撮影開始時刻のタイムスタンプを基準に目視で対応づけ, ペアとして統合した。統合後は, タイムスタンプをキーとして iPhone / Ferret Pro の二つのサブディレクトリを持つ 1 痕跡ディレクトリに整理した。

収集した 622 件のうち, 点群生成処理およびペアリングが正常に完了した 299 件を本研究の評価に使用した。処理失敗の主な要因は, メモリ不足による生成エラーやタイムスタンプ不整合によるペアリング失敗であり, 今後の処理パイプライン改善によりデータ利用率の向上が期待される。

解析には, 各痕跡ディレクトリに含まれる二種類の点群ファイルを用いた。iPhone 側では LiDAR と画像列から再構成した pointcloud.ply を, Ferret Pro 側では高密度スキャン結果の Optimization.ply を参照する。両者はいずれも色情報を含まない純粋な幾何データであり, センサ間で形状のみを比較可能とする構成とした。

### 5. 収集データの概要

本章では, 2025 年 8 月 6 日時点で収集した痕跡点群データの概要を示す。対象は第 4 章の手順で取得した iPhone LiDAR 点群および Ferret Pro 点群のペアである。収集件数, 種別内訳, 点群密度, 時間的分布, 空間分布, 環境条件, スキャン特性, 参加者行動の観点から整理する。

#### 5.1 データ件数と種別内訳

2025 年 7 月 17 日～8 月 6 日の 21 日間で, 合計 622 件のデータを収集した。対象は主にシカとイノシシの足跡であり, その他に少数の不明・小動物・タヌキなどが含まれる。また, 足跡が存在しない「負例」として地面のみを撮影したデータも含まれる。表 2 に内訳を示す。




図 5: iPhone PLY 点群の点数分布. 赤破線=平均 (6,879 点), 橙破線=中央値 (7,193 点)




図 6: Ferret Pro PLY 点群の点数分布. 赤破線=平均 (1,046,374 点), 橙破線=中央値 (1,083,788 点)

本表から, シカの観測が全体の約 3 分の 2 を占め, イノシシが約 13% を占めていることが分かる。一方で, 不明ラベルや小動物・タヌキといった少数のデータはまとめて 1.4% 程度である。さらに, 全体の約 2 割は足跡が存在しない負例 (地面のみのデータ) であり, これらは検出器の誤検出抑制や評価に有用なネガティブサンプルとなる。

#### 5.2 点群密度の分布

図 5 は iPhone 点群の点数分布, 図 6 は Ferret Pro 点群の点数分布である。iPhone は平均 6,879 点, 中央値 7,193 点に対し, Ferret Pro は平均 1,046,374 点, 中央値 1,083,788 点であり, 平均で約 152 倍, 中央値で約 151 倍の密度差が確認された。

#### 5.3 時間的分布と環境条件

図 7 は時間帯別の観測数を地面種別 (柔らかい/普通/硬い/不明) で積み上げ表示したものである。21–23 時に

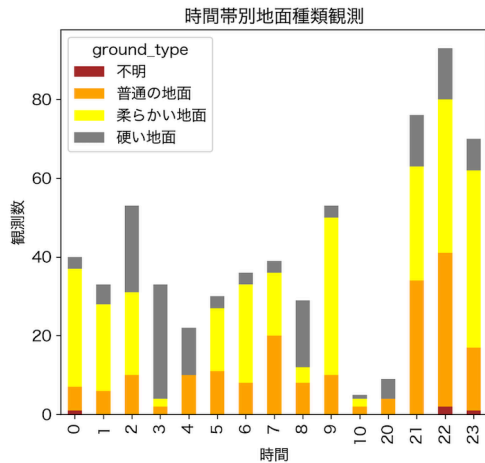


図 7: 時間帯別の観測件数 (地面種別の積み上げ)




図 8: 収集地点の空間分布 (左: ヒートマップ, 右: 点表示)

観測が集中しており, この時間帯は柔らかい地面の割合が高い. 日中帯 (9–16 時) は件数が少なく, 硬い地面の比率が相対的に高いことが分かる.

#### 5.4 位置情報の分布

図 8 に収集地点の空間分布を示す. 左はヒートマップ, 右は各サンプルの点表示である. 観測は谷筋や農道沿いに集中している一方, 周辺部にも散発的に存在していることが分かる.

## 6. 足跡判定手法

### 6.1 検出ルールの設定

本研究の候補抽出は, 地面平面推定, 残差マスク, クラスタリング, 2D 形状スクリーニングの順に実施した. 深さは地面平面の法線方向を正とし, 平面より下側 (凹み) を負と定義する.

まず, 統計的外れ値除去 ( $k=20$ , 標準偏差比  $\sigma=2.0$ ) で孤立点を除去した. 続いて, RANSAC (最大 1,000 反復) で初期平面を推定し, インライア距離しきい値を  $\tau_{\text{inlier}}$  とし, 内点を抽出したのち, それらに最小二乗フィットを行い法線  $\mathbf{n}$  と平面  $P$  (オフセット  $d$  を含む) を得た. 各点の符号付き距離を  $r=\langle \mathbf{n}, \mathbf{x} \rangle - d$  とし, 凹みの深さを  $h=-r$  と定義する. 深さしきい値は  $h_{\text{min}}$  とし,  $h \geq h_{\text{min}}$  を満たす点のみを残すことで残差マスクを適用した ( $\tau_{\text{inlier}}$  と

表 3: 検出ルールの主パラメータ (単位)

項目	Ferret (opt)	iPhone
$\tau_{\text{inlier}}$ [m]	0.004	0.020
$h_{\text{min}}$ [m]	0.020	0.020
$\varepsilon$ [m]	0.006	0.060
minPts	20	10
$L$ [m]	0.05–0.20	0.05–0.25
$S$ [m]	0.04–0.15	0.03–0.15
$L/S$ [-]	0.5–2.0	0.5–2.3
$A$ [m <sup>2</sup> ]	0.001–0.020	0.0005–0.025

$\tau_{\text{inlier}}$ : RANSAC インライア閾値,  $\varepsilon$ : DBSCAN 近傍半径, minPts: DBSCAN 最少点数.

$h_{\text{min}}$  の値は表 3 に示す).

マスク後の点群に対して DBSCAN によりクラスタリングを行う. 近傍半径を  $\varepsilon$ , 最少点数を minPts とし, センサ特性に応じて設定する (表 3). 最後に, 各クラスを平面  $P$  に直交射影し, 2 次元で外接直方体 (AABB) の長辺  $L$ ・短辺  $S$ , 縦横比  $L/S$ , および凸包面積  $A$  を算出し, 所定範囲に収まるクラスを候補として保持した.

ここで, Ferret Pro の高密度点群に基づいて設定した基準値を「opt ルール」と呼び, iPhone の低密度点群に適用する際には, 点群の希薄さに対応するため閾値を緩和した「iPhone ルール」を用いた.

補足として,  $\varepsilon$  はセンサの点間隔に比して十分大きく設定しており, Ferret Pro (点間隔 0.2–0.5 mm) では 6 mm, iPhone (点間隔 20–30 mm) では 60 mm とした. AABB と凸包面積は平面射影後の 2 次元で算出し, 縦横比は  $L \geq S$  の定義に基づいて評価する.

### 6.2 木ベース手法による分類

ランダムフォレストを用いた二値分類の試行を行った. 入力特徴量には三系統を用意した. 第一に点群の幾何的特徴として, 総点数, 凸包面積, 密度指標, および高さ分布統計量 (分位点, 分散など) を用いた. 第二に地面関連指標として, 平面フィッティング後の残差分布や RMS 誤差を加え, 足跡の凹凸を捉えるようにした. 第三に環境要因として, 観測時の天候や地面種別ラベルを導入し, 検出が困難となる条件を特徴量で補正できるようにした.

前処理では, 欠損を含む数値特徴量は中央値で補完し, カテゴリ変数については最頻値で補完した上で One-Hot エンコーディングに変換した. これにより入力空間を数値ベクトルに統一し, モデルに直接投入できる形式を整えた.

学習には scikit-learn 実装のランダムフォレストを用いた. 決定木の本数は 100 とし, 分割基準には Gini 不純度を採用した. 各木の深さには制限を設けず, 全データに対して柔軟な分割を許容した. 学習時のサンプリングはブートストラップありとし, 特徴量選択は  $\sqrt{d}$  法則に従って行った.



評価は 3-fold cross-validation により行った。fold ごとに訓練・検証を分割し、検証データに対して予測確率を出力した。この確率値に対して閾値を 0.0–1.0 の範囲で 0.01 刻みに変化させ、各点で Recall, Specificity, Balanced Accuracy を算出した。

ここで Recall は実際に足跡が存在するサンプルを正しく「陽性」と判定できた割合（真陽性率）、Specificity は足跡が存在しないサンプルを正しく「陰性」と判定できた割合（真陰性率）、Balanced Accuracy は Recall と Specificity の平均であり、クラス不均衡な状況でも全体的な判別性能を評価できる指標である。最終的には Balanced Accuracy が最大となる閾値を fold ごとに決定し、その値を用いて最終予測ラベルを与えた。

## 7. 結果

本章では、2025 年 8 月 6 日時点で収集したデータを用いた検出・分類実験の結果を示す。混同行列はいずれも fold 合算であり、陽性クラスは「足跡あり」、陰性クラスは「足跡なし（地面）」である。本評価集合は陽性比率が高いため、Accuracy に加えて Specificity と Balanced Accuracy を併記する。

### 7.1 使用データセットの概要

福井県山間部で取得したニホンジカおよびイノシシの足跡点群を用いた。本検証で利用した評価集合は合計 299 件（陽性 267、陰性 32）であり、陽性には明瞭な足跡に加えて部分的に崩れた痕跡や判別が難しい痕跡も含まれる。

### 7.2 検出ルールの 4 パターン比較

まず、ルールベースによる判定結果を示す。図 9 は Ferret Pro 点群と iPhone 点群に対し、opt ルール・iPhone ルールを相互適用した 4 条件の混同行列である。ここで、TP (True Positive) は正例を正しく検出した件数、FP (False Positive) は負例を誤って正と判定した件数を意味する。

opt ルールは Ferret Pro で Recall 98.4%, iPhone でも 95.3% の高い再現性を示したが、Specificity はそれぞれ 3.3%, 13.3% と低く、誤検出が多い結果となった。一方 iPhone ルールは TP=0, FP=0 となり、Precision と F1 は定義不能、Recall=0%, Specificity=100%, Balanced Accuracy=50% に留まった。このことから、陰性（地面）に対する誤検出抑制と再現性の両立が主要課題であることが分かる。

### 7.3 ランダムフォレストによる二値分類の結果

次に、ランダムフォレストを用いた二値分類の結果を示す。入力特徴量には点群幾何量、地面関連指標、および環境要因を用い、3-fold cross-validation により評価を行った。予測確率に対して閾値を 0.0–1.0 の範囲で探索し、

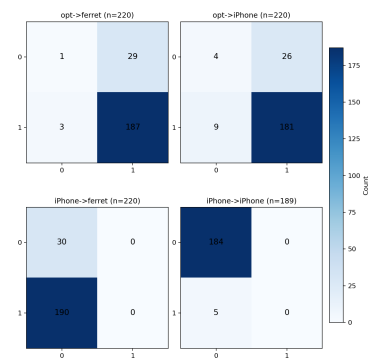


図 9: 4 パターン適用時の混同行列 (Ferret Pro / iPhone × opt / iPhone ルール)




図 10: 二値分類の混同行列 (Ferret Pro データ) 図 11: 二値分類の混同行列 (iPhone データ)

Balanced Accuracy が最大となる値を各 fold で採用した。

図 10 と図 11 は、それぞれ Ferret Pro 点群と iPhone 点群を対象とした場合の混同行列である。Ferret Pro では Recall 97.4%, Precision 92.9%, F1 95.1% を達成したが、Specificity は 37.5% に留まり、Balanced Accuracy は 67.5% であった。一方 iPhone では Recall を 96.1% に維持したものの、FP の増加により Precision は 83.7%, Specificity は 16.2%, Balanced Accuracy は 56.2% と低下した。このことから、iPhone 点群に対しては陰性クラスの識別性能が不足しており、負例データの追加学習や閾値のさらなる調整が必要であると考えられる。

## 8. 考察

本研究では、現場運用可能な iPhone 搭載 LiDAR を中心とする収集系を構築し、同一足跡を高密度スキャナでも取得することでペアデータを整備した。点群・静止画・環境メタデータを一体で管理し、取得から後処理までの手順を標準化したため、野外の微小凹形状に対する再現可能な評価基盤が得られた。この設計により、センサ密度差の影響を同一条件下で切り分けて検証できる。

学習・評価の結果は、Recall が高く Specificity が低い傾向を一貫して示した。ここで Specificity が低いとは、実際には足跡が存在しない地面を、誤って「足跡あり」と判定してしまうケースが多いことを意味する。すなわち見逃しは抑えられる一方で誤報が多く、足跡検出の実運用では誤

報対処コストと見逃しコストのトレードオフが直ちに生じる。このため、Accuracy のみを指標とするのは不十分であり、クラス不均衡を踏まえた Balanced Accuracy と不確実性の扱いが重要である。

センサ密度差については、Ferret の高密度点群では厳格な形状制約により高い再現性が得られ、iPhone の低密度点群でも劣化は限定的で追従した。一方で iPhone は Specificity の低さが目立ち、陰性識別が脆弱である。さらに iPhone 向けの一部設定では TP=0, FP=0 となり、Balanced Accuracy が偶然水準（50%）に留まった。これは固定しきい値に依存した運用が環境条件や点群密度の変動に対して脆弱であることを示す。

以上より、本研究の収集設計は、センサ特性と分類挙動を結び付けて原因を特定できる枠組みを提供したといえる。特に、密度差が Specificity に及ぼす影響と、しきい値設計の脆弱性が定量的に示された点は、次章の展望に繋がる具体的な改善方針を与える。

## 9. おわりに

本研究では、参加型センシングの枠組みで iPhone 搭載 LiDAR を中核とする足跡点群の収集・管理系と、検出・分類の初期ベースラインを構築した。同一痕跡を高密度スキャナ（Ferret Pro）でも取得して対照し、ドメイン差（密度差）を明確にした上で 4 パターン比較を行った結果、高品質点群では高い再現性を得やすく（opt→Ferret）、iPhone 点群でも限定的な劣化で追従できる一方、Specificity が不足する課題を確認した。また、iPhone ルールの一部設定では TP=0, FP=0 となり、Balanced Accuracy が偶然水準（50%）に留まることも示され、固定しきい値運用の限界を明らかにした。さらに木ベース手法の試行から、重み付け・確率校正・しきい値最適化により不均衡下でも挙動を調整できる見通しを得た。

次の課題は、より精緻な教師データを整備し、検出から分類へと発展可能なアノテーション体系を構築することである。中心点やスケールに基づく最小限の情報にとどまらず、領域抽出や輪郭分割を含むアノテーションを導入することで、「検出（有無・位置）→セグメンテーション（輪郭・趾の分離）→細分類」という三段階パイプラインへの接続が容易になる。また、抽出領域に幾何的特徴（面積、縦横比、趾間角、深さなど）を付与することで、マルチタスク学習や段階的の分類への拡張も現実的となる。

今後は、Specificity の底上げと Balanced Accuracy の改善を主眼に、足跡検出を強化する。精度向上のために深層学習を導入し、PointNet++, DGCNN, Transformer 系の点群エンコーダや 3D セグメンテーションによる輪郭・趾分離を組み合わせて、検出から細分類までを一貫処理する。加えて、教師データ仕様とデータ処理コードを公開可能な範囲で整備し、検出・分類のベンチマーク化と再現性の確

立を進める。本稿で示した土台の上で、住民参加による広域データと機械学習を接続し、生息域推定・行動モニタリングの高解像度化に貢献する。

## 参考文献

- [1] 農林水産省. 令和 5 年度野生鳥獣による農作物被害状況について, 2024.
- [2] 由田翔吾, 松田裕貴, 諏訪博彦, and 安本慶一. 参加型痕跡センシングと地理情報を用いた害獣出没地域推定手法の提案. *情報処理学会関西支部 支部大会 講演論文集*, 2023.
- [3] Kenta Shinoda, Hiroshi Tanaka, and Masako Suzuki. Smartphone lidar for wildlife footprint analysis: Performance evaluation. *Ecological Engineering*, 198:107032, 2024.
- [4] Zhenyu Yuan, Xiaoqing Li, Yujie Wang, et al. Animalclue: A large-scale dataset for indirect evidence-based animal species identification. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025. Accessed: 2025-08-08.
- [5] Ka-Hei Ng, Wenhan Yang, Dong Wang, et al. Animal kingdom: A large and diverse dataset for animal behavior understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 18888–18898, 2022.
- [6] Charles R Qi, Li Yi, Hao Su, and Leonidas J Guibas. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.
- [7] Yue Wang, Yongbin Sun, Ziwei Liu, Sanjay E Sarma, Michael M Bronstein, and Justin M Solomon. Dynamic graph cnn for learning on point clouds. *ACM Transactions on Graphics*, 38(5):1–12, 2019.
- [8] Hengshuang Zhao, Li Jiang, Jiaya Jia, Philip Torr, and Vladlen Koltun. Point transformer. *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 16259–16268, 2021.
- [9] Xin Huang, Yulan Guo, and Ying Zou. Deep learning-based 3-d point-cloud classification: A systematic survey and outlook. *Computers & Graphics*, 114:1–24, 2023.
- [10] Jakub Kulicki, Alexander Smith, and Maria Johnson. Terrestrial lidar and deep learning for forest structural monitoring: A review. *Current Forestry Reports*, 11(2):75–96, 2025.
- [11] Gregor Lützenburg, Aart Kroon, and Anders A. Björk. Evaluation of the apple iphone 12 pro lidar for an earth science application. *Scientific Reports*, 11(1):13511, 2021.
- [12] Holger Caesar, Varun Bankiti, Alex H. Lang, Sourabh Vora, Venice Erin Liong, Qiang Xu, Anush Krishnan, Yu Pan, Giancarlo Baldan, and Oscar Beijbom. nuscenes: A multimodal dataset for autonomous driving. In *CVPR*, 2020.
- [13] Pei Sun, Henrik Kretschmar, Xerxes Dotiwalla, et al. Scalability in perception for autonomous driving: Waymo open dataset. In *CVPR*, 2020.
- [14] Angela Dai, Angel X. Chang, Manolis Savva, Maciej Halber, Thomas Funkhouser, and Matthias Nießner. Scannet: Richly-annotated 3d reconstructions of indoor scenes. In *CVPR*, 2017.
- [15] Iro Armeni, Ozan Sener, Amir R. Zamir, et al. 3d semantic parsing of large-scale indoor spaces. In *CVPR*, 2016.