

# リールセンサデータを用いた 海上釣り堀における釣り動作・状態認識

小手川 康太<sup>1</sup> 小嵜 泰造<sup>1</sup> 松井 智一<sup>1</sup> 松田 裕貴<sup>2</sup> 諏訪 博彦<sup>1</sup> 安本 慶一<sup>1</sup>

**概要：**SNS や動画配信文化の浸透により釣り体験に対するニーズが多様化する中で、釣り堀などの各種釣り施設におけるリアルタイムな釣果状況と混雑度の正確な把握がより重要となっている。本研究では、リールに装着したセンサから得られる時系列データを用いて釣り人の状態遷移を自動認識する手法を提案する。釣りを 5 つの基本状態（仕掛け準備中、仕掛け沈下中、待ち中、ファイト中、仕掛け回収中）で定義し、センサデータから 3 つの特徴的動作（仕掛け投入、釣り上げ、仕掛け回収）を 1 次元畳み込みニューラルネットワーク（1D-CNN）により認識する。これらの動作認識結果と状態遷移の制約を組み合わせることで、従来困難であった「釣り上げ」動作を含む釣り人の連続的な状態把握を実現する。海上釣り堀において 9 名の被験者から収集したデータを用いた実証実験により、提案手法の有効性を検証した。極端なクラス不均衡により現実的な条件（その他クラスのサンプルを全部含めた場合）でのマクロ平均 F1-Score は 51.65% に留まつたが、バランス調整後（その他クラスのサンプル数を 5% にダウンサンプリングした場合）では 71.9% まで向上し、手法の潜在的な能力を確認した。混同行列の分析から、同じリール巻き動作である釣り上げと仕掛け回収の識別が可能であることを確認し、1D-CNN が微細な動作特性の違いを効果的に捉えることを実証した。本研究により、従来困難であった「釣り上げ」動作を含む詳細な釣り状態の定量化における技術的可能性と限界、さらには、釣り堀の運営最適化と利用者への情報提供に向けた基盤技術の方向性が示唆された。

## 1. はじめに

釣りは日本で人気の高いアウトドアレジャーの一つであるが、長期的には人口減少傾向にある。公益財団法人日本生産性本部が発行する『レジャー白書 2024』[1] によると、2023 年の釣り人口は 510 万人となっており、2006 年の 1,290 万人から半分以下に減少している。しかし、釣り人口の減少にも関わらず、長期的には市場規模の拡大傾向が続いている。一人当たりの投資額増加や機器の高級化が進んでいる [2]。この変化の背景には、釣り体験の質的变化がある。近年、SNS の浸透により、釣り動画（Vlog）の人気が急速に高まっている。多くの釣り人が自身の釣り体験を記録・共有することを期待しており、特に若年層では「映える」釣り体験やデータに基づいた釣り戦略への関心が高まっている。このような背景から、釣り堀のような手軽にアクセスでき、安定した釣果を提供する施設への需要が拡大している。

このような変化により、釣り堀における客観的な釣れ具

合（釣果状況など）の把握が重要な課題となっている。運営者は効率的な施設運営のため、利用者は限られた時間での効果的な釣り体験のため、それぞれリアルタイムな状況情報を必要としている。しかし、従来の目視確認や断片的な報告では、釣り堀全体の客観的な状況把握は困難である。

特に釣り堀では、不特定多数の釣り人が長時間にわたり釣りを楽しむレジャー空間であるため、プライバシーへの配慮が重要である。カメラを用いた画像認識による状況把握は、釣り人の意図しない撮影や、くつろいだ釣り体験を阻害する可能性がある。また、釣り人の移動や休憩時に他の利用者を意図せず撮影してしまうリスクも存在する。このため、釣り堀のようなレジャー施設においては、プライバシーを保護しつつ客観的な状況把握を実現する手法が求められている。

さらに、単純な釣り上げ動作の検出だけでは、釣り場全体の活動状況や効率性を詳細に把握することは困難である。釣り人の状態遷移（仕掛け準備、投入、待機、釣り上げ、回収）を連続的に認識することで、より詳細な釣り場分析と運営最適化が可能となる。

従来の取り組みでは、釣りにおける特定行動の技術向上支援 [3] や、トラブル検出 [4]、魚信検出による釣果向上 [5]

<sup>1</sup> 奈良先端科学技術大学院大学  
Nara Institute of Science and Technology  
<sup>2</sup> 岡山大学  
Okayama University

など、個人の技術・釣果改善に焦点を当てたものが中心である。釣り場全体の状況把握や運営支援という観点からのアプローチは未開拓である。特に、実際の「釣り上げ」を含む詳細な行動状態を認識することで、客観的な釣れ具合を量化解する手法は確立されていない。

本研究では、リールに装着したセンサから得られる時系列データを用いて、釣り人の状態遷移を自動認識する手法を提案する。具体的には、釣り行動を5つの基本状態（仕掛け準備中、仕掛け沈下中、待ち中、ファイト中、仕掛け回収中）で定義し、センサデータから3つの特徴的動作（仕掛け投入、釣り上げ、仕掛け回収）を1次元畳み込みニューラルネットワーク（1D-CNN）により認識する。これらの動作認識結果と状態遷移の制約を組み合わせることで、釣り人の連続的な状態把握を実現する。

海上釣り堀でのデータ収集を通して、提案手法の有効性と限界を明らかにする実験を行った。9名の被験者から収集したデータを用いた評価では、極端なクラス不均衡により現実的な条件（その他クラスのサンプルを100%使用）でのマクロ平均F1-Scoreは51.65%に留まったが、バランス調整後（その他クラスのサンプル数を5%に削減）では71.9%まで向上し、手法の潜在的な能力を確認した。一方で、実用化には現実的なデータ分布での性能向上が不可欠であることも判明した。これにより、従来困難であった「釣り上げ」を含む詳細な釣り状態の量化解における技術的可能性と限界を示し、釣り堀の運営最適化と利用者への情報提供に向けた基盤技術の方向性を提示した。

## 2. 関連研究

### 2.1 レジャー活動における行動認識研究

レジャー活動における行動認識の分野では、ウェアラブルセンサを用いた手法が広く研究されている[6]。Xiaら[7]は、手首装着型IMUセンサを用いてラケットスポーツ（卓球・バドミントン）の行動認識を実現した。IMU、MCU、Bluetoothを統合したリアルタイムシステムにより、9種類の行動を86.9%～98.1%の精度で分類し、リアルタイムでの結果表示を可能にしている。このようなスポーツ分野での行動認識技術は、短時間かつ集中的な行動パターンを対象として高い成功を収めている。

しかし、釣りは従来のスポーツ行動認識とは大きく異なる特徴を持つ。釣りは数時間に及ぶ長時間活動であり、釣り竿から手を離す「ながら行動」、待機時間中の自由な行動など、規則性の低い例外的な行動が頻繁に発生する。さらに、釣り糸・餌・魚という複数の媒介物を通じた間接的な相互作用のため、身体装着型センサでは限界がある。これらの理由から、釣り分野では道具への直接的なセンサ装着が有効なアプローチとなる。

### 2.2 釣り行動認識に関する既存研究

釣り分野における行動認識研究として、福田ら[8]は釣竿に装着したIMUセンサを用いて釣り人の行動認識システムを開発した。このシステムは、投げる、リールを巻く、移動する、エサをつける、待つといった5種類の基本行動をF値78.4%の精度で認識し、GPS情報と組み合わせることで釣り人の位置と活動のマッピングを実現している。また、釣果が無い時における意思決定支援のための釣りCPS（Cyber Physical System）も提案しており、IoTで得られる情報とサイバー空間の情報をAIが解析し、釣り人にフィードバックするシステム構想を示している。

より具体的な釣り技術の認識に焦点を当てた研究として、近藤ら[3]は個人の技術向上を目的とし、リールに装着したセンサからキャスト行動の種類（オーバーヘッドキャスト・サイドキャスト・ピッチング）を高精度（98.1%）で分類する手法を提案した。同研究では被験者6名から360回のキャスト行動データを収集し、LightGBMを用いた機械学習により、Leave-One-Session-Out交差検証で98.1%，Leave-One-Person-Out交差検証で86.9%の精度を達成している。

### 2.3 本研究の位置付け

既存研究では後述する「釣り上げ動作」（魚がかかるから取り込みまでの一連の動作）が対象とされておらず、釣り堀全体のリアルタイムな釣果状況を把握することができない。福田らの研究[8]では、釣り人の位置と基本的な活動パターンは把握できるが、実際の釣果は得られない。釣り上げ動作の認識は技術的に困難である。従来研究で対象とされてきたキャスト等の動作は釣り人が主体的に行う能動的動作であるのに対し、釣り上げ動作は魚の不規則な抵抗や動きを含む相互作用的な動作であるためである。魚の種類や大きさによって抵抗パターンが大きく変動し、この自然との相互作用を伴う動作認識は、人間が制御可能な動作の認識とは根本的に異なる課題となる。

さらに、既存研究は瞬間的な動作の分類に焦点を当てており、釣り活動の本質である長時間にわたる状態遷移を捉えていない。釣りは「待機→アタリ（魚が餌に食いつく反応）→アワセ（針を魚の口にかける動作）→釣り上げ→取り込み」といった状態変化を伴う活動であり、従来の瞬間的な動作認識では状態間の遷移パターンを適切に捉えることができない。また、釣り上げ行動は魚の不規則な抵抗パターンを含むため認識が困難である。これらの課題に対し、本研究では、海上釣り堀における釣り行動を、図1の、5つの基本状態（仕掛け準備中、仕掛け沈下中、待ち中、ファイト中、仕掛け回収）を含む状態遷移図として定義した。この状態遷移モデルにより、釣り上げ動作を含む釣り活動全体を認識する手法を提案し、釣り場における釣果状況の定量的評価を可能にする。

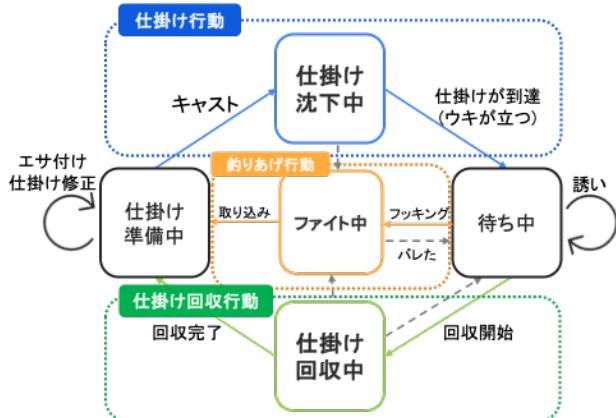


図 1 釣り人の状態遷移図

### 3. 提案手法

#### 3.1 釣りの状態定義と認識対象動作

図 1 に示すように、釣り人の状態遷移 5 つの状態のうち、「仕掛け準備中」と「待ち中」では特徴的なセンサ信号パターンを示さないため直接識別は困難である。一方、「仕掛け沈下中」「ファイト中」「仕掛け回収中」では特徴的な動作を伴うため、本研究では 3 種類の動作（仕掛け動作、釣り上げ動作、仕掛け回収動作）を認識することで状態を推定する。状態遷移図の制約により、動作が検知されない期間は「仕掛け準備中」または「待ち中」と推定可能であり、最後に認識された動作から、どちらかの状態であるかを識別できる。このように、3 種類の動作の認識結果と状態遷移の論理的制約を組み合わせることで、釣り人の全状態を連続的に把握する。認識対象の 3 つの動作を、以下のように定義する。

**仕掛け投入動作：** 仕掛け準備中からキャスティング（釣り竿を振って仕掛けを投げ入れる動作）開始により仕掛け沈下中へ遷移し、タナ（目標とする水深）到達で待ち中へ移行する。沈下中の魚ヒットや回収開始により途中終了する場合もある。

**仕掛け回収動作：** 待ち中または沈下中からリール巻き開始により仕掛け回収状態へ遷移し、完全水揚げで準備中へ戻る。回収中の魚ヒットにより途中でファイト中へ遷移する場合もある。

**釣り上げ動作：** 待ち中/仕掛け沈下中/仕掛け回収中のいずれかの状態からヒットよりファイト中へ遷移し、魚の取り込み成功または魚のバレ（魚が針から外れて逃げること）により他の状態へ復帰する。

#### 3.2 動作認識手法

本研究では、リールセンサから得られる時系列データに対して、ウィンドウベースの 1 次元畳み込みニューラルネットワーク（1D-CNN）による 4 クラス分類（その他の動作を含む）を用いて釣り動作の認識を行う。1D-CNN は

組み込みシステムや IoT デバイスでのセンサデータ処理において広く採用されている軽量な手法であり [9–13]、限られた計算資源下でも効率的な推論が可能である。また、1D-CNN は釣り動作の特徴抽出にも適している。釣り動作における特徴的なセンサパターン（キャスト時の急激な加速度変化、釣り上げ時の不規則な負荷変動、回収時の周期的なリール回転など）は時系列上の局所的な特徴として現れるため、畳み込み演算による特徴抽出が効果的である。

## 4. 実験

### 4.1 実験目的と概要

本実験では、海上釣り堀における釣り動作の自動認識システムの有効性を検証することを目的とする。具体的には、リールセンサから得られる時系列データを用いて、3 章で定義した 3 つの釣り動作（仕掛け投入動作、釣り上げ動作、仕掛け回収動作）およびその他の状態を機械学習により自動分類し、その精度を評価する。

実験は以下の手順で実施する。まず、神奈川県三浦市の海上釣り堀において、リールセンサとカメラを用いた実データ収集を行う。次に、収集したカメラ映像をもとに各釣り動作のアノテーションを実施し、リールセンサデータにラベルリングを行う。その後、ラベル付きデータを用いて 1D-CNN による 4 クラス分類モデルを構築し、データ分布の異なる 2 つの実験設定（元データそのままとダウンサンプリング調整）でモデル性能を評価し、提案手法の有効性を検証する。

データ収集は海上釣り堀で一般的に行われるウキ釣りを対象とする。海上釣り堀は有料施設であるため利用者が限られた時間内での釣果を重視し、釣果状況の把握需要が高い。また、運営者は魚の放流タイミングや餌付け状況の管理を行う必要があり、海上という特殊環境では安全管理の観点からも利用者の活動状況を把握することが重要である。被験者はウキを用いたエサ釣りで、アタリを視認してからアワセを行い、その後リールを巻いて魚を取り込む一連の釣り動作を行う。

### 4.2 データ準備

#### 4.2.1 実験環境

データ収集には釣り竿に取り付けたリールセンサとウェストマウントを利用して被験者の胸部に取り付けたカメラを利用した。実験中は両デバイスの時刻データにずれが起きないように実験中は定期的にデバイスの時刻同期を行った。実験には異なる釣り経験を持つ 9 名の被験者が参加し、自然に釣りを行っている最中の動作全体をデータ収集の対象とした。

#### 4.2.2 デバイス構成

##### カメラシステム

映像撮影には、GoPro HERO12 Black および DJI Osmo

Action 5 Pro を使用した。両カメラともに 4K 解像度、30fps の設定で撮影を行い、広角機能を利用して釣り竿と手元の様子を広い視野角で記録した。カメラはチェストマウントを用いて被験者の胸部に装着し、釣り行動の全体を捉えられる角度で設置した。撮影された映像は休憩や時刻同期、バッテリー交換などのタイミングで被験者によって適宜停止・再開されており、実験中の様子は複数の映像ファイルによって記録されている。

各被験者のリールには、慣性測定装置 (IMU) を含む釣り専用センサを装着した。センサは約 20ms のサンプリング間隔でデータを記録し、基本センサデータとして 3 軸加速度・角速度 (AccelX/Y/Z, GyroX/Y/Z), クラッチ状態、スプール移動量 (1 回転=4 パルス), キャストブレーキ状態を取得した。これらの基本データから、スプール位置・回転速度、キャスト状態判定、合成加速度・角速度、仰角などの特徴量を算出し、釣り動作認識に必要な 11 次元のセンサデータセットを構築した。

#### 4.2.3 アノテーション

データ収集後は、カメラ映像をもとに、3 種類の動作（仕掛け投入動作、釣り上げ動作、仕掛け回収動作）の開始時刻と終了時刻を特定した。アノテーション作業は 2 名のアノテーターによって実施され、自作したアプリケーションを用いて図 2 のように各動作の時間区間を記録した。

映像に記録されていない時間帯のリールデータについてはデータとして利用せず、各動作において開始時刻や終了時刻が映像から読み取れない場合、および 3 つの定義に該当しない曖昧な動作については全て記録対象外とした。映像内で動作の開始から終了までが完全に記録されている区間のみに対してアノテーションを行った。

#### 4.2.4 データ前処理

収集したリールセンサデータは、元々約 20ms のサンプリング間隔で取得されていたが、データの時間軸を正規化するため 50ms 間隔 (20Hz) にリサンプリングを行った。リサンプリングには線形補間を用いてタイムスタンプの統一を図った。このリサンプリング後のデータに対して、4.2.3 で述べた映像ベースのアノテーション結果を適用し、各時刻における動作ラベルを付与した。ラベリングは 3 章

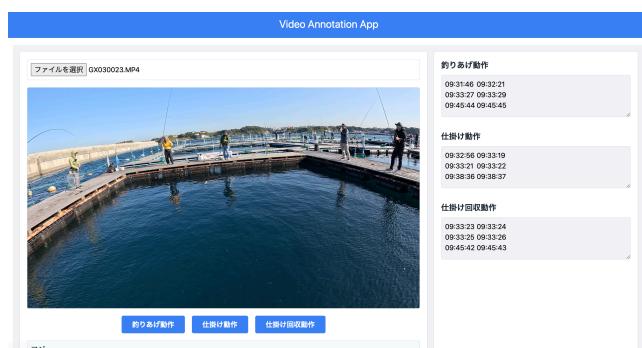


図 2 アノテーション作業風景

表 1 データセット構成

クラス	ウィンドウ数	割合 (%)
CastSettle (仕掛け投入)	28,870	6.9
HookRetrieve (釣り上げ)	9,390	2.2
RetrieveRig (仕掛け回収)	8,427	2.0
Other	374,296	89.1
合計	420,983	100.0

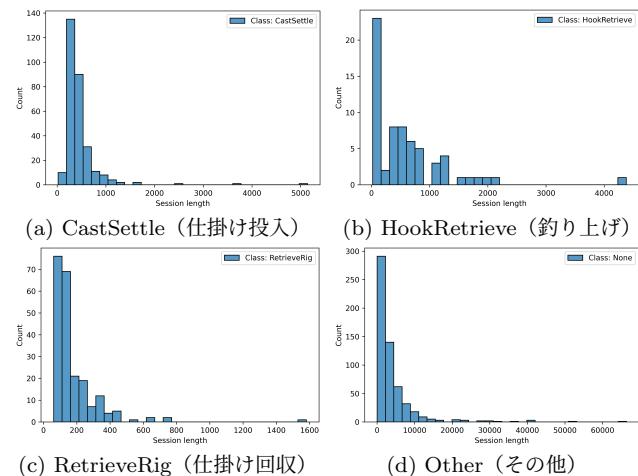


図 3 各クラスのセッション長分布

で定義した 3 つの動作（仕掛け投入動作、釣り上げ動作、仕掛け回収動作）および 3 つの動作のいずれも発生していない区間（Other）の 4 クラスで実施した。

機械学習による動作認識のため、リサンプリング後の時系列データをスライディングウィンドウ方式で固定長のウィンドウに分割した。ウィンドウサイズは 10 秒 (20Hz × 10 秒 = 200 サンプル), ストライドは 1 サンプル (50ms) とし、1 サンプルずつずらしながらウィンドウを移動させることでセグメントを生成した。使用した特徴量は、基本センサデータとして 3 軸加速度 (AccelX, AccelY, AccelZ), 3 軸角速度 (GyroX, GyroY, GyroZ), クラッチ状態 (Clutch), スプール移動量 (PulseCount), キャストブレーキ状態 (Brk), 糸長情報 (LineLength)，および算出特徴量として合成加速度 (AbsAccel) を含む 11 次元のセンサデータである。これらの特徴量は、海上釣り堀における釣り動作認識に必要な基本的な物理量と釣り状態を表現している。ウィンドウのラベルは、ウィンドウ内のサンプルにおいて最も出現頻度の高いラベルを採用した。

#### 4.2.5 データセット概要

##### クラス分布

実験で使用したデータセットの構成を表 1 に示す。用意したデータセットには Other クラスが全体の 90% 近くを占める極端なクラス不均衡が存在する。これは釣りの特性上、待機時間が大部分を占めるためである。極端なクラス不均衡問題に対処するため、次の 2 つの実験設定で Other クラスのダウンサンプリングを実施した。

設定 1 では実際のセンシング環境下での認識精度を検

表 2 1D-CNN アーキテクチャ

層番号	層の種類	パラメータ	出力サイズ
1	畳み込み層 + ReLU	入力:11ch, 出力:64ch, カーネル:5, ストライド:1, パディング:2	-
2	畳み込み層 + ReLU	入力:64ch, 出力:128ch, カーネル:5, ストライド:1, パディング:2	-
3	畳み込み層 + ReLU	入力:128ch, 出力:128ch, カーネル:5, ストライド:1, パディング:2	-
4	適応的平均プーリング層	出力サイズ:1	128 × 1
5	全結合層 + ReLU	128 次元 → 128 次元	128
6	出力層	128 次元 → 4 次元	4

証するために、Other クラスの全てを利用している。設定 2 では実際のセンシング環境とか異なるものの、不均衡がない場合に、各動作がどの程度他の動作と間違えやすいのかを確認するために、Other の数を 5% にランダムダウンサンプリングして認識を行う。5%で行うのは 3 クラスで最もウィンドウ数の多いクラスと概数を合わせるためである。：

- **設定 1 (Other 100%)**：全 Other ウィンドウを使用
- **設定 2 (Other 5%)**：Other ウィンドウを 5% にランダムダウンサンプリング

釣り動作の各クラスにおけるセッション長の分布を図 3 に示す。横軸のセッション長は、連続する同一ラベルの時間区間の長さを表している。仕掛け投入動作 (CastSettle) と釣り上げ動作 (HookRetrieve) に関しては多くのセッションが 0 から 2000 (100 秒) ほどに収まっている一方で、極端に長いセッションが存在することが確認された。仕掛け回収動作 (RetrieveRig) は多くのセッションが 400 (20 秒) 以内に収まっており、他の動作と比較して短時間で完了する傾向が見られた。

外れ値となる長時間セッションについて目視確認を行った結果、実際の釣り環境における様々な要因が影響していることが判明した。仕掛け投入における外れ値は、強風の影響により仕掛けの着底が視覚的に判断しにくい状況で発生しており、アノテーション時の判断の困難さが反映されている。釣り上げ動作の外れ値については、大型の青魚の釣獲時におまつり（糸絡み）が発生し、通常よりも長時間を要するケースが確認された。仕掛け回収における外れ値は、魚の当たりが曖昧な状況において、様子を見ながら慎重に引き上げる動作や、海底の根掛かりなどのイレギュラーな現象により時間を要した場合が多く見られた。

#### 4.3 釣り動作認識モデルの構築

##### 4.3.1 1DCNN アーキテクチャ

釣り動作分類に利用した 1D-CNN のネットワーク構成は表 2 の通りである。モデルは Adam オプティマイザを使用し、学習率 1e-5、バッチサイズ 256、エポック数 10 で学習を実施した。クラス不均衡問題に対処するため、損失関数には重み付き CrossEntropyLoss を使用した。出力層で

は、HookRetrieve (釣り上げ), CastSettle (仕掛け投入), RetrieveRig (仕掛け回収), Other (その他) の 4 クラス分類を行う。

##### 4.3.2 データ分割とセッション管理

モデル評価の信頼性を確保するため、適切なデータ分割戦略を実装した。データリークを防ぐため、セッション単位でのデータ分割を実装した。セッションは、連続する同一ラベルの時間区間として定義し、同一の釣り動作が継続している期間を一つの単位として扱った。全セッションを 6:2:2 の比率で訓練・検証・テストセットに分割し、同一セッション内のウィンドウが異なるセットに分散しないよう配慮した。この分割方法により、隣接する類似ウィンドウによる過度に楽観的な評価を回避し、モデルの汎化性能を適切に評価できる環境を構築した。

## 5. 結果と考察

### 5.1 結果

提案手法による釣り動作認識の性能を表 3 に示す。設定 1 の環境下での認識精度は全体精度 83.09% で、マクロ平均 F1-Score は 51.65% という結果であった。設定 2 のダウンサンプリングを行なったケースでは、全体精度は 74.94% とやや低下したもの、3 つの釣り動作 (HookRetrieve, CastSettle, RetrieveRig) の認識精度が大幅に改善されマクロ平均 F1-Score は 71.9% を達成した。

混同行列を図 4 に示す。Other 100% 設定では、3 種類の釣り動作クラスから Other クラスへの誤分類が多く発生している。Other 5% 設定では、これらの誤分類が大幅に減少し、釣り動作の検出精度が向上していることが確認できる。

### 5.2 ダウンサンプリング効果による認識精度向上

設定 1 で高い精度を示すことができなかった背景として、全体の 89.1% を占める Other クラスに対してモデルが過度に最適化され、釣り動作の重要な特徴が多様な Other クラスに埋もれてしまっていると考えられる。一方で、設定 2 の 5% にダウンサンプリングした条件では、3 つの釣り動作すべてで F1-Score が大幅に改善された。特に RetrieveRig では +0.3846 と最も大きな改善を示し、続いて CastSettle (+0.3454), HookRetrieve (+0.2311) の順となった。この改善により、1D-CNN が各釣り動作固有の

表 3 釣り動作認識精度の比較

クラス	設定 1(その他 100%)			設定 2(その他 5%)			F1 スコア改善
	Precision	Recall	F1-score	Precision	Recall	F1-score	
釣りあげ	0.4045	0.4704	0.4350	0.7504	0.5988	0.6661	+0.2311
仕掛け投入	0.3831	0.5683	0.4577	0.8597	0.7534	0.8031	+0.3454
仕掛け回収	0.1839	0.5037	0.2695	0.6046	0.7125	0.6541	+0.3846
その他	0.9435	0.8675	0.9039	0.7005	0.8129	0.7526	-0.1513
マクロ平均	0.4788	0.6025	0.5165	0.7288	0.7194	0.7190	+0.2025

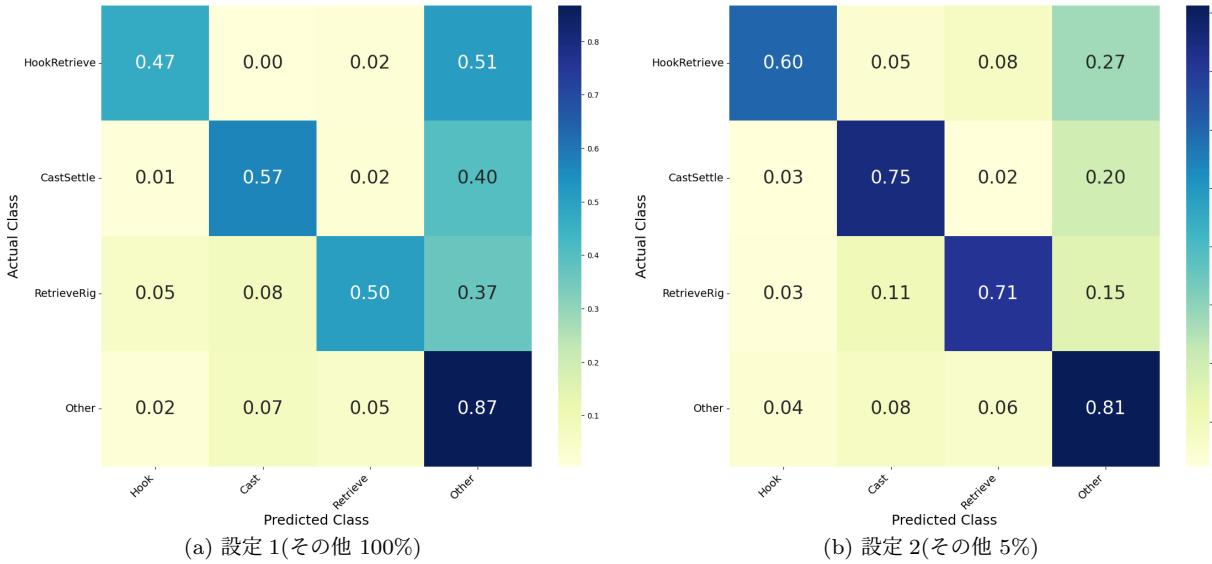


図 4 混合行列の比較

センサパターンを効果的に学習できる潜在能力を持つことが確認された。

結果から、この不均衡問題を適切に抑制できれば、3章で提案した状態遷移制約を考慮した階層的な動作認識により、現実的なデータ分布においても高精度での釣り状態推定が実現できる可能性を示している。

### 5.3 クラス間識別性能の分析

混同行列の分析から、釣り上げ動作 (HookRetrieve) と仕掛け回収動作 (RetrieveRig) 間の相互誤分類が少ないことが確認された。Other 5%設定において、HookRetrieve → RetrieveRig の誤分類は 8%，RetrieveRig → HookRetrieve は 3% に留まっている。これは、同じリール巻き動作であっても、魚の抵抗を伴う釣り上げと一定速度での仕掛け回収では、センサに現れる加速度や角速度パターンが明確に異なることを示している。

### 5.4 アノテーションの外的要因による影響

HookRetrieve と Other クラス間の誤分類については、4.2.5 で示したセッション長分布の外れ値と関連が深い。特に強風により浮きの着底確認が困難となったケースでは、実際には着底している状態を「仕掛け沈下中」とアノテーションしたり、その逆が発生している可能性がある。このようなアノテーション規則の曖昧性は、実釣環境における

外的要因（気象条件、海況等）に起因しており、映像ベースのアノテーション手法の限界を示している。より客観的な基準設定や、複数のアノテーターによる合意形成プロセスの導入が必要である。

改善案として、視覚的判断に依存しない明確なアノテーション規則の策定が必要である。例えば、「餌を仕掛けた後、クラッチを切った瞬間仕掛け投入終了」といった、釣り人の操作に基づく基準の導入が有効と考えられる。このような規則は浮きの視認性に左右されず、さらにウキを利用しない釣りスタイル（ルアーフィッシング、投げ釣り等）にも適用可能であり、手法の拡張性を大幅に向上させることができる。

### 5.5 実用化に向けた課題と解決策

現実的なデータ分布である Other 100% 設定での釣り動作認識精度向上には、根本的なアーキテクチャ改善が必要である。具体的には、「釣り中かどうか」の事前判定機能の組み込みが有効と考えられる。実験中には釣り竿から完全に手を離している時間や、釣り場から離れるシーンも含まれており、これらを事前に除外することで Other クラスの不均衡を抑制することができる。階層的分類アプローチとして、第一段階で「釣り実行中／非実行中」を判定し、第二段階で具体的な釣り動作を分類する手法の導入を検討すべきである。

異なる釣り堀環境への適用には、魚種、水深、気象条件等の多様性を考慮したデータ収集と検証が必要である。具体的には、転移学習による既存モデルの新環境適応、ドメイン不变特徴の学習による環境ロバスト性の向上が考えられる。また、釣り人の経験差やスタイルの違いに対しては、個人適応型の学習手法やメタ学習による汎化能力の向上が求められる。

## 6. まとめ

本研究では、リールに装着したセンサを用いた釣り動作・状態の自動認識手法を提案した。釣り行動を5つの基本状態で定義し、1次元畳み込みニューラルネットワーク(1D-CNN)により3つの特徴的動作(仕掛け投入、釣り上げ、仕掛け回収)を認識することで、従来困難であった「釣り上げ」動作を含む釣り活動全体の定量化手法を提案した。

海上釣り堀での実証実験により、以下の知見を得た。実際の環境下では前述の釣り動作以外に分類される動作が占める時間割合が極端に多く、それによるクラス不均衡により釣り動作の認識精度は限定的であることが判明した。一方で、ダウンサンプリングによりクラス不均衡を調整した条件では、マクロ平均F1-Score 0.72を達成し、1D-CNNが各釣り動作固有のセンサパターンを効果的に学習できる潜在能力を確認した。特に、同じリール巻き動作である釣り上げと仕掛け回収の識別が可能であることを実証し、微細な動作特性の違いを捉える手法の有効性を示した。

提案手法は、従来システムが対象としてきた釣りの個人技術向上支援のみならず、釣り場全体の状況把握システムへの活用が期待される。具体的には、比較的軽量な1D-CNNを利用し、リールセンサのみから状態遷移モデルとの組み合わせによる連続的な動作認識の枠組みを提示した。これにより、釣具の組合せや混雑状況の定量化システムの実現が期待できる。将来的には、エッジデバイスとの連携や処理のクラウド化により、リアルタイムに釣り場状況の確認が可能なシステムの実現を目指す。

本研究では動作認識精度の評価にとどまったが、提案手法の核心である「動作認識結果と状態遷移の論理的制約を組み合わせた連続的状態把握」の全体評価が今後の重要な課題である。具体的には、認識された3つの動作から状態遷移図に基づいて推定される5つの状態(仕掛け準備中、仕掛け沈下中、待ち中、ファイト中、仕掛け回収中)の精度評価と、時系列での状態遷移パターンの妥当性検証が必要である。

## 7. 謝辞

本研究の遂行にあたり、多くの方々にご協力いただきました。データ収集実験では、安田様、三屋様、沖島様、毒島様、小田様、佐々木様に実験協力者としてご参加いただ

き、貴重なデータの収集にご協力いただきました。また、海上釣り堀での実験実施にあたり、施設関係者の皆様には実験環境の提供と運営面でのご協力をいただきました。さらに、研究の各段階において貴重なご指導とご助言をいただいた関係者の皆様に深く感謝いたします。

## 参考文献

- [1] 公益財団法人日本生産性本部. レジャー白書 2024, October 2024. 余暇創研.
- [2] 一般社団法人日本釣用品工業会. 第27回「釣用品の国内需要動向調査報告書」. Technical report, 一般社団法人日本釣用品工業会, 東京都中央区八丁堀2-22-8 日本フィッシング会館, January 2024. 釣用品メーカー出荷ベース市場規模調査.
- [3] 近藤亮介, 真弓大輝, 松田裕貴, 諏訪博彦, 安本慶一. 釣り上達支援システムの実現に向けたキャスト種類の分類および評価. 人工知能学会「社会におけるAI」研究会 第49回研究会, 3 2024.
- [4] Federico Dettù, Marco Centurioni, Simone Formentin, and Sergio Matteo Savaresi. Model-based estimation of the line tension in a fishing reel. *IFAC-PapersOnLine*, Vol. 54, No. 20, pp. 122–127, 2021.
- [5] [Patent Applicant Name]. Motion sensing fish bite alarm. U.S. Patent Application No. 20180213761, August 2018. Filed: February 1, 2017.
- [6] Yu-Liang Hsu, Hsing-Cheng Chang, and Yung-Jung Chiu. Wearable sport activity classification based on deep convolutional neural network. *IEEE Access*, Vol. 7, pp. 170199–170212, 2019.
- [7] Kun Xia, Hanyu Wang, Menghan Xu, Zheng Li, Sheng He, and Yusong Tang. Racquet sports recognition using a hybrid clustering model learned from integrated wearable sensor. *Sensors*, Vol. 20, No. 6, 2020.
- [8] Shuichi Fukuda, Hyuckjin Choi, Yuki Matsuda, and Keiichi Yasumoto. Fishing activity sensing and visualization system using sensor-equipped fishing rod: demo abstract. In *Proceedings of the 18th Conference on Embedded Networked Sensor Systems*, SenSys '20, p. 615–616, New York, NY, USA, 2020. Association for Computing Machinery.
- [9] Shibo Zhang, Yaxuan Li, Shen Zhang, Farzad Shahabi, Stephen Xia, Yu Deng, and Nabil Alshurafa. Deep learning in human activity recognition with wearable sensors: A review on advances. *Sensors*, Vol. 22, No. 4, 2022.
- [10] Ayokunle Olalekan Ige and Malusi Sibiya. State-of-the-art in 1d convolutional neural networks: A survey. *IEEE Access*, Vol. 12, pp. 144082–144105, 2024.
- [11] Yafeng Yin, Lei Xie, Zhiwei Jiang, Fu Xiao, Jiannong Cao, and Sanglu Lu. A systematic review of human activity recognition based on mobile devices: Overview, progress and trends. *IEEE Communications Surveys & Tutorials*, Vol. 26, No. 2, pp. 890–929, 2024.
- [12] Santosh Kumar Yadav, Kamlesh Tiwari, Hari Mohan Pandey, and Shaik Ali Akbar. A review of multimodal human activity recognition with special emphasis on classification, applications, challenges and future directions. *Knowledge-Based Systems*, Vol. 223, p. 106970, 2021.
- [13] Song-Mi Lee, Sang Min Yoon, and Heeryon Cho. Human activity recognition from accelerometer data using convolutional neural network. In *2017 IEEE International Conference on Big Data and Smart Computing (BigComp)*, pp. 131–134, 2017.