

BLEセンシングによる人数・体感混雑度推定： 三種空間の比較実験

寺岡 莉玖¹ 細川 蓮¹ 立花 巧樹² 呉 健朗² 林 虎太郎³ 吉村 太斗³ 諏訪 博彦¹ 松田 裕貴^{3,1}

概要：都市空間における様々な環境の混雑度情報は、安全性と快適性の観点から、人々にとって関心の高い情報の一つである。また、混雑度情報を利用するのは人であることから、単なる人数把握に加えて「体感混雑度」の推定も重要であると考えられる。本研究では、コンビニエンスストア、オフィス、バーという異なる3種類の空間を対象にBLEセンシングデータを収集し、LightGBMを用いた人数推定（回帰）モデルおよび体感混雑度推定（分類）モデルを構築・比較した。分析の結果、推定精度や誤差傾向は空間の種類や利用者の行動（役割）によって変化すること確認された。特に体感混雑度の誤分類は隣接クラス間に集中する傾向が確認され、正確な分類こそ難しいものの、主観の推定としてはある程度許容範囲の精度を示すことができた。また、体感混雑度は利用者の主観的な騒がしさ評価と有意に正の相関を示すことが確認された。

1. はじめに

都市環境の様々な場所の混雑度は、都市内で滞在・移動する人々にとって関心の高い情報の一つである。近年では、COVID-19の打撃を受けた観光地にオーバーツーリズムの状況が重なっていることもあり、交通機関や飲食店、公共施設など幅広い空間において、以前にも増してその要望は存在している。また、社会全体の観点からも、混雑度を平準化する（一部の空間の過剰な混雑を避ける）ことによって、都市を遍く安全・快適に保つことが求められている。いずれの観点においても、様々な空間の混雑度を横断的に知ることが重要であるといえる。

近年では、様々な混雑度推定手法の研究が進められている。例えば、カメラやLiDARを用いる方法、モバイルデバイスに搭載されたセンサを用いる方法、Wi-FiやBLEなどの電波を用いる方法などが提案されている。こうした技術の中で、実サービス化されている事例も数多く存在する。しかし、既存の混雑度計測サービスは、導入場所・提供会社ごとに異なる方式でデータ収集および情報提供がなされることから、ユーザにとって都市空間の混雑度情報は一覽性のある形で提供されていないという現状である。また、混雑度情報を利用するのは人であることから、絶対的な人数に加えて、人がどの程度混雑していると感じるか、つまり「体感混雑度」という観点も重要であると考えられ

るが、これまでにセンシングに基づく「体感混雑度」の推定に関する研究は限られている。こうした背景から本研究では、簡易なデバイスを用いたセンシングにより、様々な空間に適用可能な混雑度・体感混雑度の推定手法の実現を目指している。

本稿では、3種類の空間に対してデータ収集を行い、機械学習モデルを用いた人数推定、体感混雑度モデルを構築・評価した。結果として、推定性能は空間の種類によって異なり、また体感混雑度モデルにおいてその空間内での行動の違いにより傾向と誤差が見られ、誤分類は隣り合う階級間に集中した。

2. 関連研究

2.1 公共空間における混雑度の推定に関する研究

コンピュータビジョン分野においては、カメラを用いた画像解析による混雑度や人流の推定は、長年にわたって研究の中心的課題となっている。Sindagiら[1]は、群集画像のグローバルおよびローカルな文脈情報を取り込む複数の畳み込みニューラルネットワーク（CNN）コンポーネントを融合し、群集密度と人数を推定する手法を提案している。Liuら[2]は、複数の受容野サイズから得られる特徴を組み合わせて混雑シーンにおける人数を推定する、Context-Aware Networkと呼ばれるエンドツーエンドで学習可能な深層アーキテクチャを提案している。新井ら[3]は、プライバシーに配慮し、カメラ画像をマクロに捉えることで、個人の検出を行うことなく駅空間の混雑度の推定

¹ 奈良先端科学技術大学院大学

² ソフトバンク株式会社

³ 岡山大学

手法を提案している。宮崎ら [4] は、群衆を個の集まりではなく群として扱うことで、従来手法では混雑により人の重なりが大きく解析が難しい状況や、追跡すべき人数が多すぎて処理が重くなる状況における高精度な認識を実現している。また、レーザーイメージング・検出・測距 (LiDAR) 技術を利用した研究やサービスも存在する。例えば、SICK AG [5] は、3D-LiDAR センサを用いて、ある領域に出入りする人数を計測するシステムを提供している。同様のアプローチは公共交通機関における混雑度推定にも活用されている [6], [7]。Song ら [6] は、監視カメラの画像から乗客数をカウントするシステムを提案している。これらのアプローチは、人の画像を直接認識することで比較的高精度な推定を可能とするが、カメラの設置や運用には高コストがかかるだけでなく、プライバシーの懸念から社会的受容性に課題があるといえる。

さらに、モバイルデバイスに搭載された各種センサを利用する手法も提案されている。Kannan ら [8] は、スマートフォンから発せられる音声信号を別のユーザのデバイスが受信し、その音響特性を解析することで混雑度を推定する参加型システムを提案している。Nishimura ら [9] は、スマートフォンから収集された加速度データと環境音データを用いて、歩行者流の円滑さを推定する手法を提案している。Moustafa ら [10] は、スマートフォンのモーションセンサを用いた乗客の行動解析と、マイクによる環境音特性の取得を組み合わせることで、鉄道駅の混雑度を推定する手法を提案している。

Wi-Fi や BLE といった電波を利用する手法も存在する。Handte ら [11] や Hidayat ら [12] は、バスの Wi-Fi アクセスポイントに接続された乗客のモバイルデバイスの MAC アドレスをカウントすることで、バス内の乗客数を推定する手法を提案している。Maekawa ら [13] は、乗客のスマートフォンを用いて周囲の Bluetooth 信号をスキャンし、混雑度を推定する手法を提案している。また、Weppner ら [14] は、特定の環境を移動する人々のモバイルデバイスが受信した BLE 信号を収集し、近傍の BLE デバイス数をカウントすることで群集密度を推定する手法を提案した。Takahashi ら [15] は、バス停における混雑度を推定するため、オーバーヘッドカメラと、人々のモバイルデバイスから送出されるブローブ要求を検出する Wi-Fi スキャナを組み合わせる手法を提案している。

2.2 これまでの研究と本稿の位置づけ

著者らは前述の背景をうけ、BLE の受信状況に基づく様々な環境に適用可能な混雑度・人流推定に関する研究に取り組んできた [16]。具体的には、路線バスや電車における混雑度推定 [17], [18] や、飲食店などの公共空間における混雑度推定 [19], オフィス空間での混雑度推定 [20] などである。また、体感混雑度に関しても調査を行っている [21]

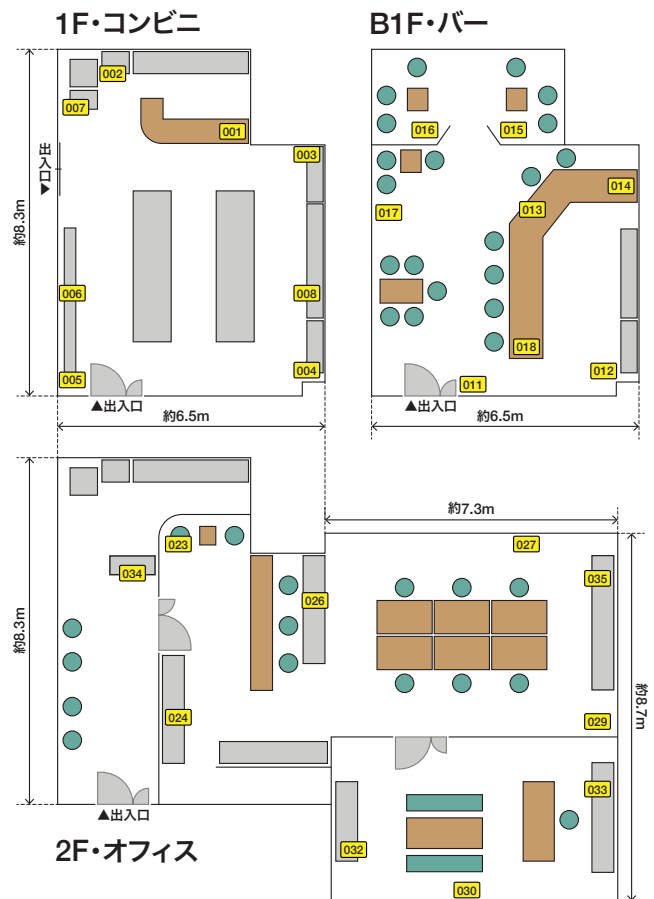


図 1: 実験対象の空間と BLE スキャナの配置

ほか、路線バスにおける体感混雑度の推定モデルの構築・評価 [22] を行っている。しかし、これらの体感混雑度の推定に関する研究報告では、交通機関における空間が対象となっていることから、他の空間において既存の体感混雑度推定手法が適用可能かどうかについては検証できていない。

そこで本稿では、複数の空間を対象とした実験を通じて、商店・職場・飲食店といった環境において体感混雑度の推定が可能かどうかについて検証を行うことを目的とする。

3. 実験

3.1 実験の概要

本稿では、様々な環境・状況における混雑度・体感混雑度データを収集するため、実際の環境を模したスタジオ施設*1において、実験協力者に様々な役割を与えることによって多様な状況を再現する実験を行った。

本実験においては、上記施設のうち混雑度・体感混雑度の情報提供の需要があると考えられる、コンビニエンスストア、オフィス、バーの3つの空間を対象とした。それぞれの空間の情報は表 1 に示すとおりである。実験協力者は33名である。実験協力者には、表 2 に示す役割を各参加者に割り当てた。各役割の実施時間は概ね5分間とし、役

*1 環七マルチスタジオ (<https://www.planear.co.jp/studio/multi/kannana.html>)

表 1: 実験対象の空間

空間	階層	おおよその広さ	特徴
コンビニエンスストア	1 階	約 50m ²	2 面がガラス張りで開放的。幹線道路に面している。 棚や壁・パーティションでエリアが区切られている。 窓がなく薄暗い。段差がある。
オフィス	2 階	約 90m ²	
バー	地下 1 階	約 50m ²	

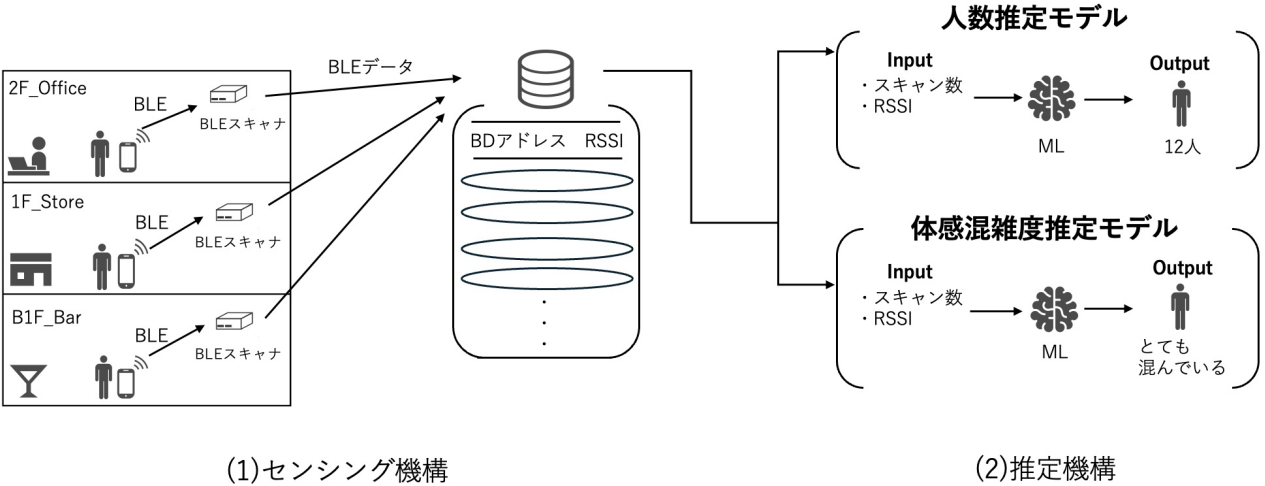


図 2: 実験およびモデル構築の概要

表 2: 実験協力者の役割

ID	空間	役割
A-1	コンビニ	雑誌の立ち読み
A-2	コンビニ	特定の商品を 5 個購入
A-3	コンビニ	雑談
A 外	コンビニ	外で待機
B-1	オフィス	カウンセリング
B-2	オフィス	コワーキングスペース
B-3	オフィス	応接間
B 外	オフィス	オフィスの入り口
C-1	バー	マスターと会話
C-2	バー	ダーツ
C-3	バー	テーブルで会話

割が切り替わる際に直前 5 分間の体感混雑度について専用のアンケート（表 3）へ回答する形式とした。この手続きを計 63 回反復し、三空間において合計 1,865 件のアンケート応答を取得した（コンビニ：767 件、オフィス：579 件、バー：519 件）。なお、未回答により 119 件分の回答は欠損している。アンケートは専用の Android アプリを用いて収集し、アンケート入力時の干渉を避けるため当該端末の Bluetooth は無効化した状態で操作させた。併せて、実環境の端末混在を再現するため参加者は個人所有のスマートフォンを Bluetooth 有効の状態で行き来して実験に参加した。

各空間の大まかな形状、BLE スキャナの配置、実験協力者の役割ごとの位置（指定がある場合）を図 1 に示す。役

割毎の位置を緑の丸、BLE スキャナを黄色の四角でそれぞれ示している。本実験では様々なセンサ設置位置・組み合わせにおける混雑度・体感混雑度の推定を広く調査するため、バーとコンビニに 8 個、オフィスに 10 個の BLE スキャナを配置した。

3.2 分析手法の概要

本稿では、BLE スキャナ群を用いて、異なる屋内環境における混雑度推定モデルを構築する。具体的には、コンビニエンスストア、オフィス、バーといった商店・職場・飲食店を代表する屋内空間を対象とし、役割ベースの実験とアンケートに基づく主観ラベルおよび実験計画に基づき付与した人数ラベルを対応させたデータを構築する。実験およびモデル構築の概要を図 2 に示す。得られたウィンドウ単位の BLE ログから、ユニーク端末数および信号強度に関する特徴量を抽出し、これらを入力として、機械学習により体感混雑度の分類および人数の回帰を行う。

3.3 体感混雑度の定義

混雑度の指標には、客観的な混雑度である人数と、主観的な混雑度である利用者の感じる「体感混雑度」が存在する。同一空間においても、レイアウトや人の配置、利用者の行動により、同一人数であっても体感混雑度は異なる可能性がある。図 3 には、コンビニ、オフィス、バーにおける人数と体感混雑度の関係を示している。図 3 を確認する

表 3: 実験協力者が回答するアンケート

質問 ID	設問	回答の選択肢
Q1	混雑しているように感じましたか？	1: 全く感じなかった ～ 5: とても感じた
Q2	騒がしいと感じましたか？	1: 全く感じなかった ～ 5: とても感じた
Q3	室内の快適さ（暑さ・寒さ）はどう感じますか？	5: 暑い, 4: やや暑い, 3: 適温, 2: やや寒い, 1: 寒い
Q4	室内の明るさはどう感じますか？	5: 明るい, 4: やや明るい, 3: 普通, 2: やや暗い, 1: 暗い

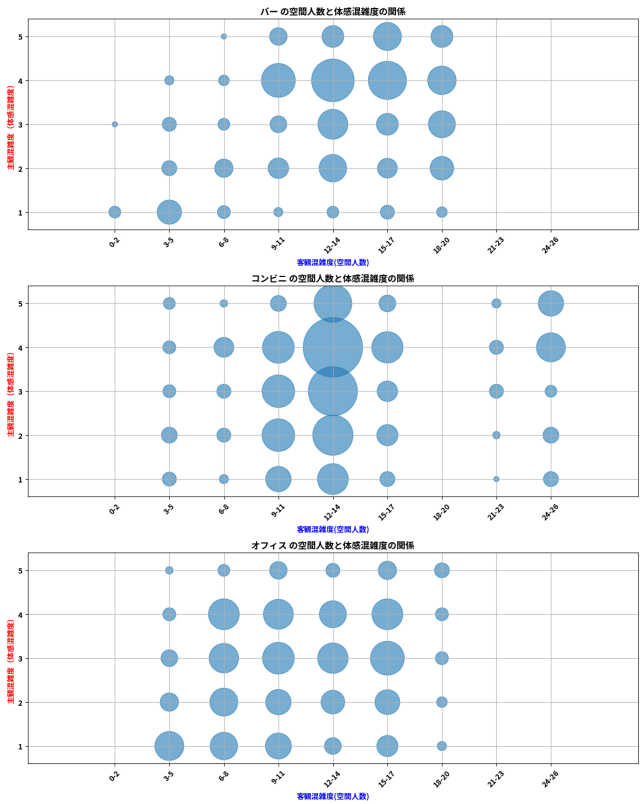


図 3: 人数と体感混雑度の関係

と、人数と体感評価の間にばらつきが存在することが確認できる。このことは、人数推定に加えて、体感混雑度を推定することが重要であることを示している。

本稿では、各ウィンドウ内に記録された BLE 信号データを用いて、そのデータから、抽出されるスキャナ別のユニーク端末数や検出イベント数、RSSI の分布統計や閾値帯（パケット）ごとの出現件数などを特徴量とする。

正解ラベルについては、主観ラベルとして参加者のアンケートによる体感混雑度（5 段階）を用いる。客観ラベルの人数は実験計画に基づき各ウィンドウの在室人数として付与する。このデータを用いて、本研究は特徴量から体感混雑度を予測する分類モデルと、人数を推定する回帰モデルの学習を目的とする。

3.4 データセット

それぞれの空間に設置した BLE スキャナでは、時刻情報とスキャンされた各デバイスの Bluetooth Device Address（以降、BD アドレス）および BLE の受信信号強度

（RSSI）の組を取得する。使用する BLE スキャナは Raspberry Pi 4 または Raspberry Pi 5 をベースとし、取り付けした Bluetooth 4.0+EDR/LE Class1 対応 USB アダプタ（BUFFALO 社製、BSBT4D105BK）によって BLE データを取得、デバイス内に蓄積する。時刻同期はネットワーク経由で行う。BLE のスキャン周期はいずれも 1 秒とした。

本研究では、3 種類の空間（コンビニ、オフィス、バー）に設置した複数の BLE センサから得られる 1 秒間隔のスキャンログ（RSSI、端末固有アドレス）と、参加者アンケート（体感混雑度：5 段階尺度、および補助設問）を用いる。BLE ログは、タイムスタンプを揃えた上で、アンケート回答時刻および人数観測時刻と突き合わせて学習データを生成する。推定タスクは人数の回帰と体感混雑度の分類である。

3.5 前処理と特徴量設定

混雑度予測するための特徴量として、アンケート回答時刻 t_s の直近 4 分区間 $[t_s - 4min, t_s]$ のスキャンを対象とし、各センサごとにユニーク端末数 `ble_count` の統計量（mean/std/min/max/median/q25/q75）、RSSI を閾値 $-90, -80, -70, -60, -50, dBm$ で区切った各バケットの出現件数について同様の統計量を計算する。回帰タスク（人数）では、人数観測時刻 t_c の ± 30 秒区間 $[t_c - 30s, t_c + 30s]$ で同様の統計量を算出する。いずれのタスクでも、1 秒生データの時間内ゆらぎを抑制するため、中央値サンプリング（median pooling）を用いている。

3.6 混雑度推定モデル

混雑度予測をするための学習器として、両タスクともに LightGBM を用いる。人数推定は回帰モデル、体感混雑度推定は多クラス設定（体感混雑度 1-5）による分類モデルとする。クラス不均衡への対策として、SMOTE による少数クラスの過学習防止を、各学習折の訓練データ内のみに適用する。評価手順は k-fold-out ($k = 10$) とし、ハイパーパラメータはフロア間・センサ間の比較可能性を担保するため共通設定を基本としている（学習率、木の深さ、葉数など）。早期終了は検証の F1（分類）／RMSE（回帰）で判定する。

4. 分析結果

本研究では単一センサごとに回帰モデル（人数推定）と

表 4: 各フロア別人数推定モデル精度（最良学習モデルの結果例）

各フロア	センサ	MAE	MAPE	RMSE
バー	S17	3.72	51.2	4.77
コンビニ	S1	3.98	35.1	5.24
オフィス	S32	3.24	34.5	4.25

表 5: 各フロア別体感混雑度推定モデル精度（最良学習モデルの結果例）

各フロア	センサ	Accuracy	Precision	Recall	F1-measure
バー	S18	0.28	0.31	0.28	0.29
コンビニ	S5	0.29	0.31	0.29	0.29
オフィス	S29	0.27	0.27	0.27	0.27

分類モデル（体感混雑度推定）を構築し、各フロア（コンビニ、オフィス、バー）別にその精度を比較した。各推定モデルのフロア別の最も精度が良かったセンサの推定結果を表 4、表 5、図 4、図 5 に示す。

バーにおいては、回帰は MAE3.72, RMSE4.77, MAPE51.2%前後を示し、小人数帯で数人のズレが MAPE を押し上げ、散布図でも $\pm 30\%$ を超える誤差が散見された。分類は Accuracy が 0.28, F1 が 0.29 であり、真値が 4 における ± 1 クラスのずれが目立つ。

コンビニにおいては、回帰は MAE が 3.98, RMSE が 5.24, MAPE が 35.1%を示し、散布図では $y = x$ 近傍に比較的集中し、 $\pm 10 \sim 30\%$ 帯に収まる点が多い。一方、分類は Accuracy が 0.29, F1 が 0.29 であり、 $3 \leftrightarrow 4 \leftrightarrow 5$ の境界における ± 1 クラスのずれが中心であった。

オフィスでは、回帰は MAE3.24, RMSE4.25, MAPE34.5%を示し、中間域の $\pm 10 \sim 20\%$ 帯に集中する傾向が見られた。分類は Accuracy が 0.27, F1 が 0.27 であり、過小に推定される傾向が見られた。

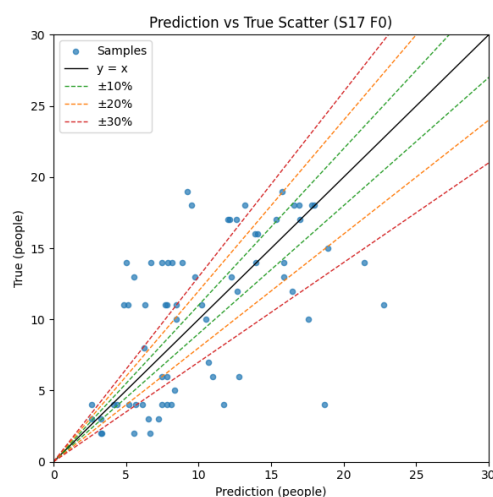
総じて、両タスクで共通して最良のセンサは見られず、客観人数と主観混雑度の最適な観測位置が異なることが示唆された。

したがって、目的（客観／主観）に応じてセンサを選定、あるいは複数センサの合成指標による統合を行うことが、実運用上の精度向上につながると考えられる。


5. 考察

5.1 体感混雑度推定と行動の関係


アンケートで指示された役割（例：雑誌の立ち読み、特定の商品を買等）と体感混雑度推定との関係を表 6 に示す。表 6 より、役割ごとの誤分類率はいずれも 70%以上と高く、厳密な一致率に基づく評価は困難であることが確認された。しかし、役割別の混同行列図 6 を確認すると、多くの誤りは $\pm 1 \sim 2$ 段階以内に集中しており、 ± 3 以上の大きな外れは比較的少数に留まることが分かる。すなわ



(a) バー・センサ 17



(b) コンビニ・センサ 1



(c) オフィス・センサ 32

図 4: フロア別の人数推定モデルの推定結果（最良学習モデルの結果例）

ち、予測誤りは序数的な性質を持ち、近傍クラス間での取り違えが多いと考えられる。したがって、体感混雑度は観

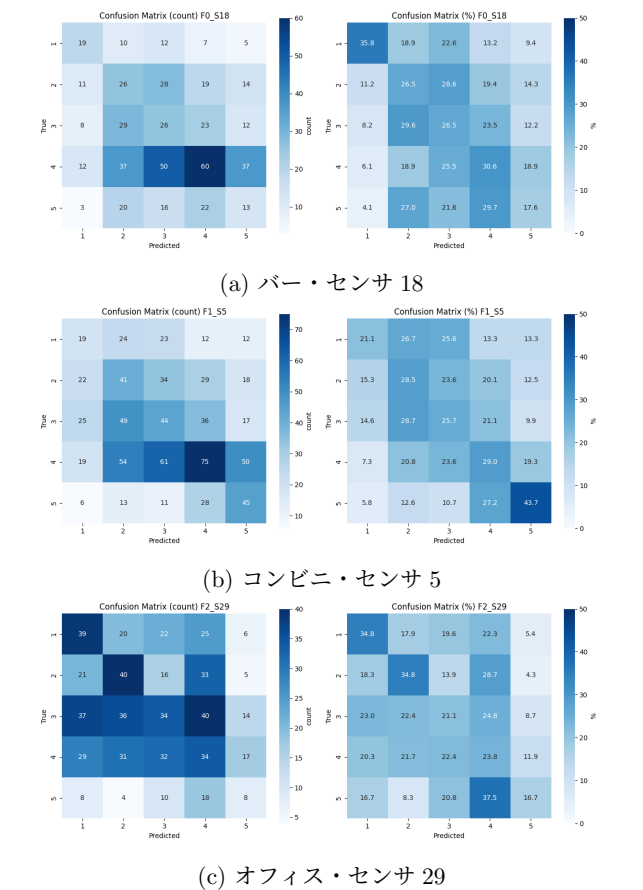


図 5: フloor別の体感混雑度推定モデルの分類結果（最良学習モデルの結果例）

測者の主観に依存する尺度であり、個人差があるため、近傍クラスでの誤分類は、ある程度許容できる。

また体感混雑度の誤分類の原因を詳細に把握するために、役割別にどの誤りが多いかを調査し、「コワーキングスペース」「カウンセリング」「特定の商品を5個購入」における上位の誤分類ペアを図7にまとめた。図7aより「コワーキングスペース」では真値4に対して2や1への過小推定、逆に2から4への過大推定が併存していることが分かった。また「カウンセリング」では真値3を中心に上下のクラスへの散りが顕著であることが図7bから読み取れる。さらに、図7cに示す「特定の商品を5個購入」では真値4から3や5、あるいは2へのズレが多いことがわかり、買い物行動に伴う一時的な滞留や分散が、混雑度の推定を困難にさせていると考えられる。その他の役割においても、総じて中間帯（3～4）を中心とした±1の誤りが多く、体感混雑度の推定としてはある程度許容できる範囲である一方で、役割ごとに過小・過大の方向性に偏りがみられた。

役割ごとに誤りの方向性や幅が系統的に異なることから、役割条件付きの閾値最適化を行うことで、過小・過大バイアスの緩和が期待できる。さらに、役割や場所の組み合わせを特徴量として拡張したり、時系列的な変動率を導

表 6: 行動別体感混雑度誤分類率

行動	空間	合計	誤り	誤分類率
コワーキングスペース	オフィス	2350	1811	0.77
カウンセリング	オフィス	880	670	0.76
マスターと会話	バー	1456	1101	0.76
外で待機	コンビニ	984	739	0.75
応接間	オフィス	1800	1305	0.73
オフィスの入り口	オフィス	760	542	0.71
雑誌の立ち読み	コンビニ	1488	1061	0.71
特定の商品を5個購入	コンビニ	1672	1179	0.71
雑談	コンビニ	1992	1402	0.70
ダーツ	バー	768	538	0.70
テーブルで会話	バー	1928	1350	0.70

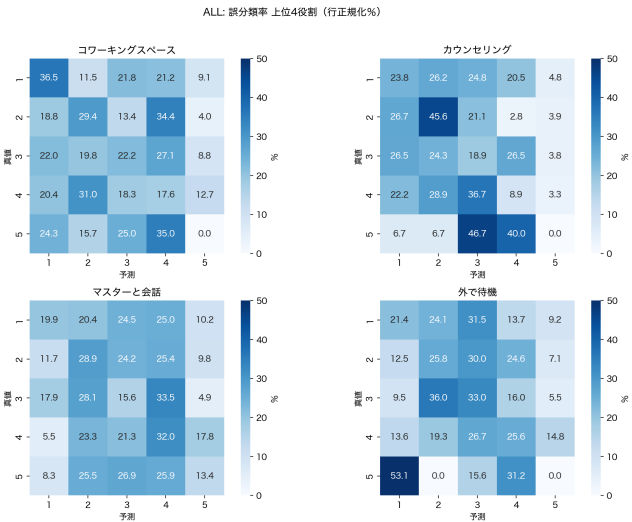



図 6: 役割別の混同行列の行正規化分布

入したりすることで、中間帯クラスの分離性を高める可能性があると考えられる。


5.2 体感混雑度とアンケート結果の関係

体感混雑度推定の精度向上を図る為、体感混雑度（質問1）とその他の環境要因に関する主観評価（質問2～4）との関係を分析し、その結果を図8に示す。図より、体感混雑度と空間の主観的騒がしさ（質問2）の間には、有意な相関が観察された（Spearman $\rho=0.54$ ）。一方で、温冷感（質問3）や明るさ（質問4）との間には、有意な相関は確認されなかった（Spearman $\rho=0.02$, $\rho=-0.01$ ）。


さらに、体感混雑度と空間の主観的騒がしさの関係を場所別に分析した結果、特にバーにおいて騒がしさと体感混雑度の相関が高いことが図9から明らかとなった（Spearman $\rho=0.77$ ）。このことは、同程度の騒がしさであっても、環境の種類によって体感混雑度の評価が変化する可能性を示唆している。今後は、場所特性や環境特性などを指標化し、それらの特徴量として加え、それらの変数がどのように予測に影響するかを検討する予定である。



(a) コワーキングスペースにおける上位誤りペア



(b) カウンセリングにおける上位誤りペア



(c) 特定の商品を5個購入における上位誤りペア

図 7: 役割毎の上位誤りペア




図 8: 体感混雑度とその他アンケート結果の関係




図 9: フロア別の体感混雑度と騒がしさの関係

6. おわりに

本研究では、単一センサごとに人数（回帰）と体感混雑度（分類）のモデルを構築し、フロア別に精度を比較する

とともに、役割別誤りとアンケート（騒がしさ等）との関係を分析した。結果として、推定性能は空間の種類によって傾向が異なり、特に体感混雑度推定モデルにおいて、行動（役割）に起因する誤りの方向や幅にも系統性が見られ、おおむね近傍クラス間での取り違えが多かった。また、体感混雑度は騒がしさと有意に相関していることが確認された。今後は、騒がしさ等の音環境特徴の導入、閾値最適化、目的（客観／主観）に応じたセンサ選定・統合で実運用精度を高める。

謝辞

本研究の一部は、JSPS 科研費（JP24K20763）、JST 共創の場形成支援プログラム（JPMJPF2115）の助成を受けて行われたものです。

参考文献

- [1] Vishwanath A Sindagi and Vishal M Patel. Generating High-quality Crowd Density Maps using Contextual Pyramid CNNs. In *Proceedings of the IEEE international conference on computer vision*, pp. 1861–1870, 2017.
- [2] Weizhe Liu, Mathieu Salzmann, and Pascal Fua. Context-aware Crowd Counting. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, CVPR'19, pp. 5099–5108, 2019.
- [3] 新井啓之, 伊藤直己, 谷口行信. 群衆をマクロにとらえる画像処理技術～人物・群衆の幾何モデルに基づいた人数推定とその応用～. 研究報告コンピュータビジョンとイメージメディア (CVIM), 第 190 巻, pp. 1–8, 2014.
- [4] 宮崎真次, 宮野博義, 池田浩雄, 大網亮磨. 群衆行動解析技術を用いた混雑推定システム. NEC 技報, 第 67 巻, pp. 82–85, 2014.
- [5] SICK AG. Counting People with 3D-LiDAR Sensors. <https://www.sick.com/us/en/industries/building-management/access-control-gates/counting-people-with-3d-lidar-sensors/c/p616144>, (Accessed on 03.14.2023), 2020.
- [6] Hongquan Song, Xuejun Liu, Xingguo Zhang, and Jiapei Hu. Real-time Monitoring for Crowd Counting using Video Surveillance and GIS. In *2012 2nd International Conference on Remote Sensing, Environment and Transportation Engineering*, pp. 1–4. IEEE, 2012.
- [7] Ejaz Ul Haq, Xu Huarong, Chen Xuhui, Zhao Wanqing, Fan Jianping, and Fazeel Abid. A Fast Hybrid Computer Vision Technique for Real-Time Embedded Bus Passenger Flow Calculation through Camera. *Multimedia Tools Appl.*, Vol. 79, No. 1-2, pp. 1007–1036, 2020.
- [8] Pravein Govindan Kannan, Seshadri Padmanabha Venkatagiri, Mun Choon Chan, Akhihebbal L. Ananda, and Li-Shiuan Peh. Low Cost Crowd Counting Using Audio Tones. In *Proceedings of the 10th ACM Conference on Embedded Network Sensor Systems*, SenSys '12, pp. 155–168. ACM, 2012.
- [9] Tomohiro Nishimura, Takamasa Higuchi, Hirozumi Yamaguchi, and Teruo Higashino. Detecting Smoothness of Pedestrian Flows by Participatory Sensing with Mobile Phones. In *Proceedings of the 2014 ACM International Symposium on Wearable Computers*, ISWC'14, pp. 15–18. ACM, 2014.

- [10] Moustafa Elhamshary, Moustafa Youssef, Akira Uchiyama, Akihito Hiromori, Hirozumi Yamaguchi, and Teruo Higashino. CrowdMeter: Gauging congestion level in railway stations using smartphones. *Pervasive and Mobile Computing*, Vol. 58, p. 101014, 2019.
- [11] Marcus Handte, Stefan Foell, Stephan Wagner, Gerd Kortuem, and Pedro José Marrón. An internet-of-things enabled connected navigation system for urban bus riders. *IEEE internet of things journal*, Vol. 3, No. 5, pp. 735–744, 2016.
- [12] Arief Hidayat, Shintaro Terabe, and Hideki Yaginuma. Estimating Bus Passenger Volume based on a Wi-Fi Scanner Survey. *Transportation Research Interdisciplinary Perspectives*, Vol. 6, p. 100142, 2020.
- [13] Yuki Maekawa, Akira Uchiyama, Hirozumi Yamaguchi, and Teruo Higashino. Car-Level Congestion and Position Estimation for Railway Trips Using Mobile Phones. In *Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing*, UbiComp'14, pp. 939–950. ACM, 2014.
- [14] Jens Weppner and Paul Lukowicz. Bluetooth Based Collaborative Crowd Density Estimation with Mobile Phones. In *2013 IEEE International Conference on Pervasive Computing and Communications*, PerCom'13, pp. 193–200. ACM, 2013.
- [15] Ryo Takahashi, Kenta Hayashi, Yudai Mitsukude, Masanori Futamata, Shunei Inoue, Shuta Matsuo, Shigemi Ishida, Yutaka Arakawa, and Shigeru Takano. Itocon - A System for Visualizing the Congestion of Bus Stops around Ito Campus in Real-time. In *The 18th ACM Conference on Embedded Networked Sensor Systems*, SenSys'20, pp. 697–698, 2020.
- [16] Yuki Matsuda, Hirohiko Suwa, Kotaro Hayashi, Taito Yoshimura, Arata Yoshihara, and Ismail Arai. Estimating people flow and crowdedness for various urban environments based on ble signal sensing: Practical studies. *IEICE Transactions on Communications*, pp. 1–11, 2025.
- [17] Yuji Kanamitsu, Eigo Taya, Koki Tachibana, Yugo Nakamura, Yuki Matsuda, Hirohiko Suwa, and Keiichi Yasumoto. Estimating congestion in a fixed-route bus by using ble signals. *Sensors*, Vol. 22, No. 3, pp. 1–15, 2022.
- [18] Eigo Taya, Yuji Kanamitsu, Koki Tachibana, Yugo Nakamura, Yuki Matsuda, Hirohiko Suwa, and Keiichi Yasumoto. Estimating congestion in train cars by using ble signals. In *The 2nd Workshop on Data-Driven and Intelligent Cyber-Physical Systems for Smart Cities*, DI-CPS'22, pp. 1–7, 2022.
- [19] 松田裕貴, 田谷瑛悟, 諏訪博彦, 安本慶一. Blece : ble を用いた公共施設・飲食店の混雑度推定手法. 電子情報通信学会技術研究報告, センサネットワークとモバイルインテリジェンス研究会 (SeMI) , pp. 40–45, 2022.
- [20] 上田健太郎, 松田裕貴, 伊勢田氷琴, 立花巧樹, 呉健朗, 須田哲生, 古野雅人, 諏訪博彦. Ble 受信状況を用いた混雑度推定手法のオフィスのオープンスペースへの適用. 第 46 回社会における AI 研究会 (SIG-SAI) / 社会システムと情報技術研究ウィーク (WSSIT '23) , pp. 1–7, 2023.
- [21] Yuki Matsuda. Iopt: A concept of internet of perception-aware things. In *The 12th International Conference on the Internet of Things (IoT '22)*, pp. 201–204, 2022.
- [22] Takumi Ikenaga, Yuki Matsuda, Ippei Goto, Kentaro Ueda, Hirohiko Suwa, and Keiichi Yasumoto. Using ble signals to estimate objective and subjective crowdedness levels on fixed-route buses. *IEEE Access*, Vol. 13, pp. 67488–67499, 2025.